Введение в языковые модели (LM)

Руслан Аллаяров



Правила участия

1. Приготовьте блокнот и ручку, чтобы записывать важные мысли и идеи
2. Продолжительность вебинара — 1 час 20 минут
3. Вы можете писать вопросы в чате
4. Запись вебинара будет доступна на платформе
5. Обсуждение можно продолжить в учебном чате

Проверка связи

Если у вас нет звука:

- убедитесь, что на вашем устройстве и на колонках включён звук
- обновите страницу вебинара (или закройте страницу и заново присоединитесь к вебинару)
- откройте вебинар в другом браузере
- перезагрузите компьютер (ноутбук) и заново попытайтесь зайти

Поставьте в чат:

\+ если меня видно и слышно

— если нет

Рекомендации

→ Если смотрите с компьютера

- Используйте браузеры Google Chrome или Microsoft Edge
- Если есть проблемы с изображением или звуком, обновите страницу — **F5**

→ Если смотрите с мобильного телефона или планшета

- Перейдите с мобильного интернет-соединения на **Wi-Fi**
- Если есть проблемы с изображением или звуком, перезапустите приложение на телефоне

Руслан Аллаяров

О спикере:

- окончил мехмат МГУ в 2021 г.
- обучался в аспирантуре Венского университета (Universität Wien)
- преподавал дисциплины по C++ в ВШЭ и по информационному поиску в МГУ
- 5 лет занимался инфопоиском в VK
- ML-тимлид, руковожу рекомендациями на главной странице Okko



Цели занятия

- Вспомнить, что такое языковая модель
- Познакомиться с видами современных языковых моделей

План занятия

1. Языковые модели (LM)
2. Общий пайплайн языковых моделей
3. N-граммные языковые модели
4. Языковые модели neural

Языковые модели (LM)

1

Языковая модель

Математическая модель, которая вычисляет вероятность появления определённой последовательности слов в естественном языке. Основная задача модели — оценить правдоподобность текста.

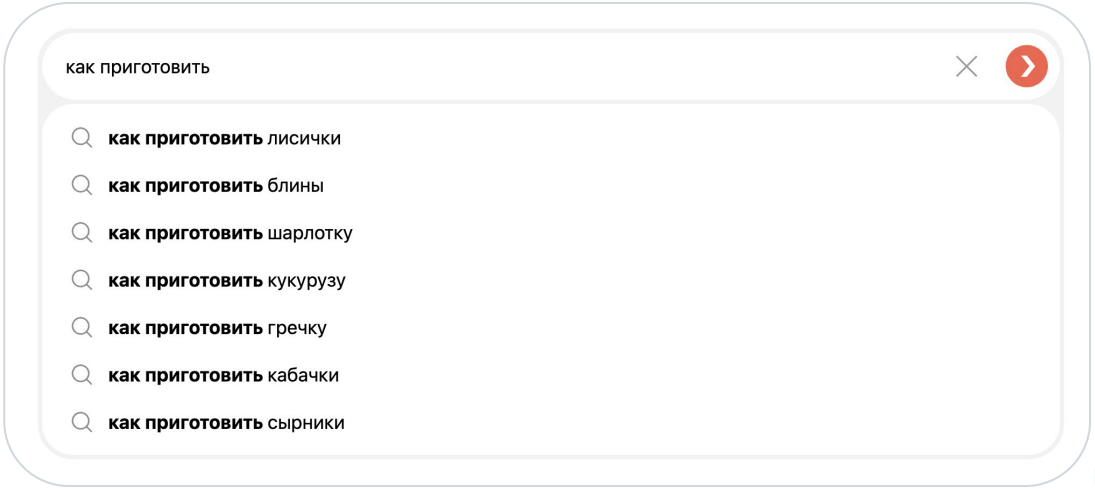
Ключевые применения:

- машинный перевод
- генерация текста
- распознавание речи
- автодополнение
- классификация текста

LM — базовый компонент многих систем искусственного интеллекта, работающих с текстом

Языковые модели. Саджесты

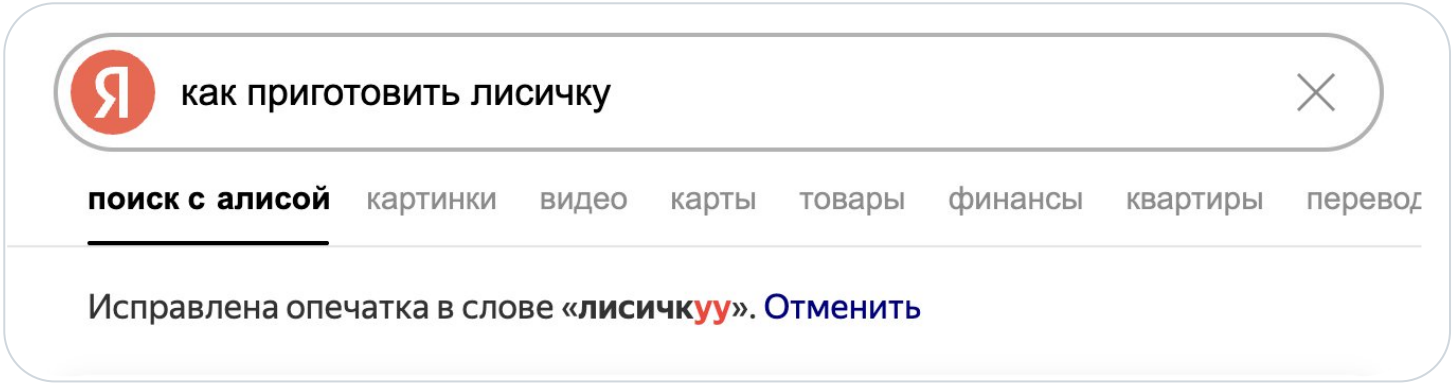
Саджесты (поисковые подсказки) — выпадающий список предполагаемых вариантов запроса, который появляется при наборе в строке поиска и формируется из популярных запросов, а также персональных и региональных факторов, чтобы ускорить и уточнить ввод



Материалы эксперта

Языковые модели. Спеллчекер

Спеллчекер (опечаточник) — система проверки правописания: автоматически находит опечатки и орфографические ошибки в тексте, подчёркивает их и предлагает корректные варианты с учётом словаря и контекста



Основные понятия

Токены

Минимальные значимые единицы текста — слова, символы, морфемы. Текст разбивается на токены для обработки

N-граммы

Последовательности из N токенов. Используются для моделирования контекста в более простых моделях

Вероятность последовательности

Оценка правдоподобности заданной последовательности токенов. Чем выше вероятность, тем более естественным считается текст

Сглаживание

Методы, предотвращающие нулевые вероятности для редко встречающихся или отсутствующих в обучающей выборке последовательностей

Эти базовые понятия — фундамент для обработки и генерации текста в языковых моделях

Общий пайплайн языковых моделей

2

Вероятность предложения: наивный подход



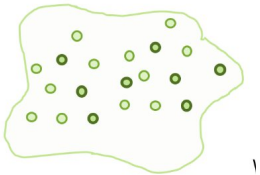
? Какова вероятность выбрать зелёный мячик?

Источник

Вероятность предложения: наивный подход



$$\frac{5}{5+6+4+3} = \frac{5}{18}$$



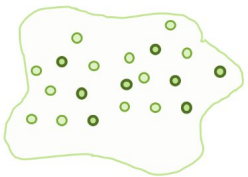
? Можем ли мы так же поступить с предложениями?

Источник

Вероятность предложения: наивный подход



$$\frac{5}{5+6+4+3} = \frac{5}{18}$$



Text corpus

$$P(\text{the mut is tinming the tebn}) = \frac{0}{|\text{corpus}|} = 0$$

$$P(\text{mut the tinming tebn is the}) = \frac{0}{|\text{corpus}|} = 0$$

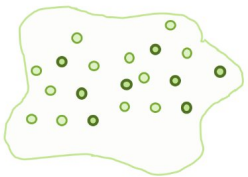
Если считать целое предложение как атомарную единицу → многие предложения вообще не встретятся в корпусе → модели дадут им ноль вероятности

Источник

Вероятность предложения: наивный подход



$$\frac{5}{5+6+4+3} = \frac{5}{18}$$



Text corpus

$$P(\text{the mut is tinming the tebn}) = \frac{0}{|\text{corpus}|} = 0$$

$$P(\text{mut the tinming tebn is the}) = \frac{0}{|\text{corpus}|} = 0$$

Если считать целое предложение как атомарную единицу → многие предложения вообще не встретятся в корпусе → модели дадут им ноль вероятности.

Первое предложение «более вероятно», чем второе, но у обоих вероятность — 0

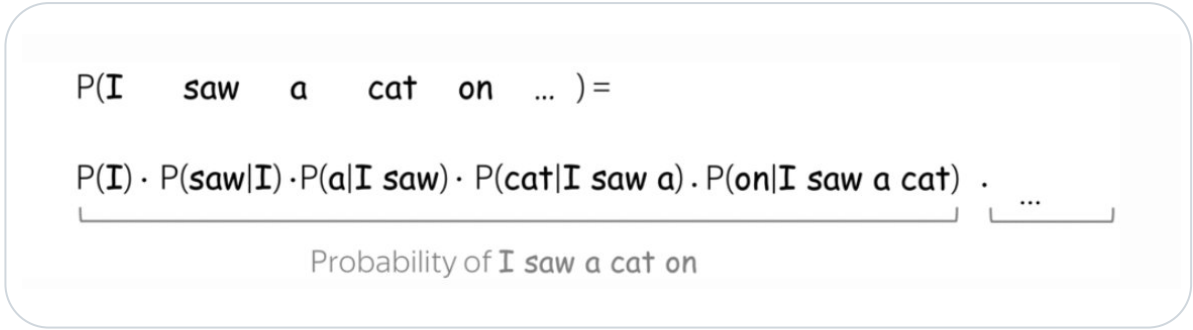
! Нужно работать с предложениями не как с неделимыми сущностями

Источник

Вероятность предложения: декомпозиция

- Читать предложение **слово за словом**
- Обновлять вероятность предложения каждый раз, когда появляется новое слово

Вероятность предложения **«I saw a cat on a mat»:**



Источник

Вероятность предложения: декомпозиция

- (y_1, …, y_n) — слова в предложении
- P(y_1, …, y_n) — вероятность увидеть предложение (слова в этом порядке)

$$P(y_1, y_2, \ldots, y_n) = P(y_1) \cdot P(y_2|y_1) \cdot P(y_3|y_1, y_2) \cdot \cdots \cdot P(y_n|y_1, \ldots, y_{n-1}) = \prod_{t=1}^{n} P(y_t|y_{<t})$$

Chain rule*

Задача: научиться считать $P(y_t|y_1, \ldots, y_{t-1})$

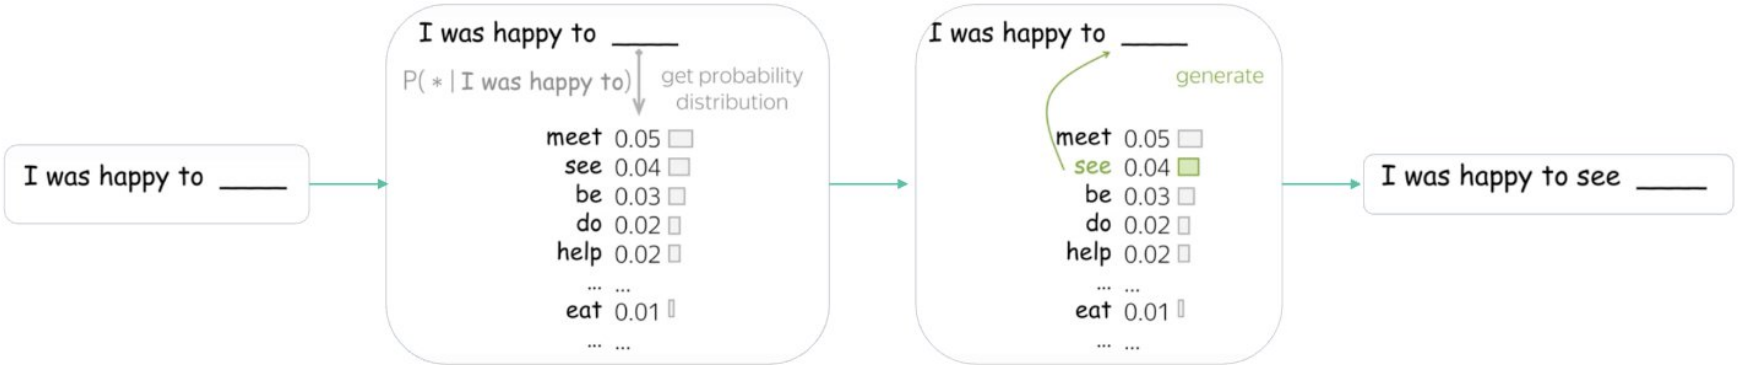
- N-gram LM
- Neural LM

Цепное правило (правило дифференцирования сложной функции)

Генерирование текста LM (верхнеуровнево)

Основная идея:

- предсказать распределение следующего токена по контексту предыдущих
- семплировать из этого распределения



Источник

N-граммные языковые модели

3

Идея

$$P(y_1, y_2, \ldots, y_n) = P(y_1) \cdot P(y_2|y_1) \cdot P(y_3|y_1, y_2) \cdot \cdots \cdot P(y_n|y_1, \ldots, y_{n-1}) = \prod_{t=1}^{n} P(y_t|y_{<t})$$

Задача — научиться считать $P(y_t|y_1, \ldots, y_{t-1})$

Решение: **приблизительно** считать статистики встречаемости по корпусу с двумя моментами:

- марковское предположение
- сглаживание

Расчёт условных вероятностей

$$P(y_t|y_1,\ldots,y_{t-1}) = \frac{N(y_1,\ldots,y_{t-1},y_t)}{N(y_1,\ldots,y_{t-1})}$$

$N(y_1, ..., y_n)$ — сколько раз предложение $(y_1, ..., y_n)$ встретилось в тексте

Аналогичная проблема: многие предложения вообще не встретятся в корпусе → $N(y_1, ..., y_n) = 0$

Как посчитать условную вероятность?

Марковское предположение

Вероятность слова зависит только от фиксированного числа предыдущих слов

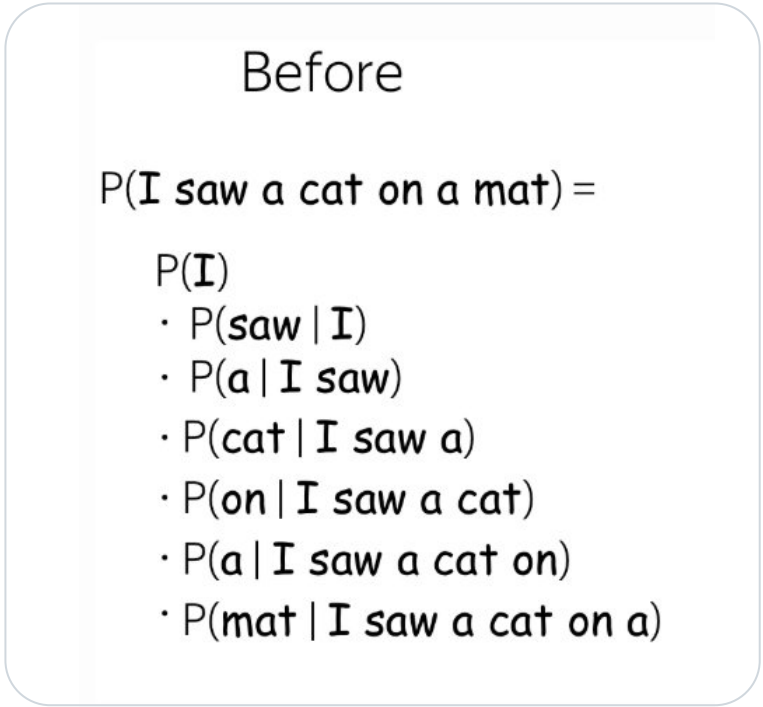
$$P(y_t|y_1,\ldots,y_{t-1}) = P(y_t|y_{t-n+1},\ldots,y_{t-1})$$

Рассмотрим только **n-1 предыдущий токен**

- n=3 (trigram model): $P(y_t|y_1,\ldots,y_{t-1}) = P(y_t|y_{t-2},y_{t-1})$,
- n=2 (bigram model): $P(y_t|y_1,\ldots,y_{t-1}) = P(y_t|y_{t-1})$,
- n=1 (unigram model): $P(y_t|y_1,\ldots,y_{t-1}) = P(y_t)$.

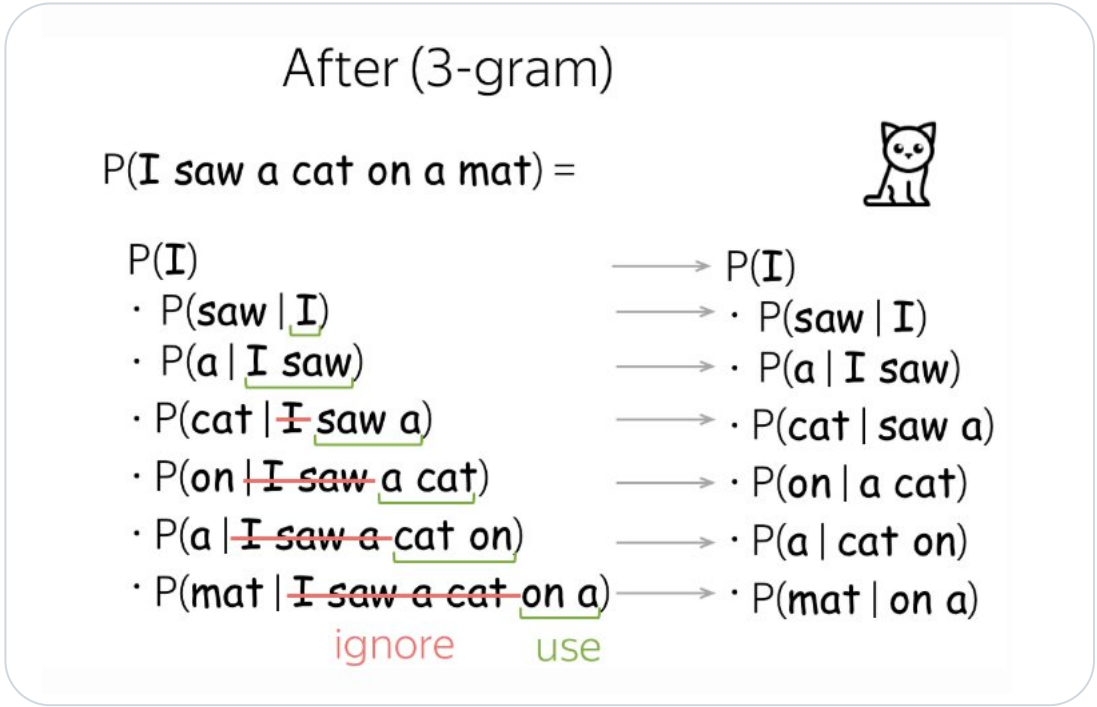
Источник

Марковское предположение



Источник

Марковское предположение



Сделаем контекст фиксированной длины назад

Источник

Сглаживание

$$P(\text{mat} \mid \text{I saw a cat on a}) = P(\text{mat} \mid \text{cat on a}) = \frac{N(\text{cat on a mat})}{N(\text{cat on a})}$$

? Какая проблема в этом случае?

Источник

Stupid backoff*

$$P(\text{mat} \mid \text{cat on a}) = \frac{N(\text{cat on a mat})}{N(\text{cat on a})} = ?$$

zero

1. **Если n-грамма встречается в корпусе**:

$$P(y_i \mid y_{i-n+1}^{i-1}) = \frac{N(y_{i-n+1}^{i})}{N(y_{i-n+1}^{i-1})}$$

где

- $N(y_{i-n+1}^{i})$ — количество вхождений всей n-граммы $(y_{i-n+1}, \ldots, y_i)$,
- $N(y_{i-n+1}^{i-1})$ — количество вхождений контекста длиной $n-1$.

---

2. **Если n-грамма отсутствует в корпусе** (*откат*):

$$P(y_i \mid y_{i-n+1}^{i-1}) = \alpha \cdot P(y_i \mid y_{i-n+2}^{i-1})$$

где

- α — фиксированный коэффициент «отката» (обычно 0.4),
- идём на уровень ниже, уменьшая порядок n-граммы.

*Эвристический метод отката вероятностей в N-граммных языковых моделях

Источник

Stupid backoff

$$P(\text{mat} \mid \text{cat on a}) = \frac{N(\text{cat on a mat})}{N(\text{cat on a})} = ?$$

zero

Недостатки:

- **нет нормализации** — сумма вероятностей не равна 1
- **фиксированный коэффициент** — α выбирается эмпирически
- **игнорирует тонкие зависимости** — не различает редкие, но важные N-граммы
- **только ранжирование** — подходит для сравнения кандидатов, но не для задач, где нужны корректные вероятности

Линейная интерполяция

$$P(\text{mat} \mid \text{cat on a}) = \frac{N(\text{cat on a mat})}{N(\text{cat on a})} = ?$$

zero

Вместо того, чтобы брать только n-грамму (или откатываться к n-1)-грамме, **комбинируются все уровни** от униграмм до N-грамм:

$$P(y_i \mid y_{i-n+1}^{i-1}) = \lambda_n \cdot \hat{P}(y_i \mid y_{i-n+1}^{i-1}) + \lambda_{n-1} \cdot \hat{P}(y_i \mid y_{i-n+2}^{i-1}) + \cdots + \lambda_1 \cdot \hat{P}(y_i)$$

где:

- $\hat{P}(\cdot)$ — частотные вероятности,
- $\lambda_k \geq 0$ — веса (гиперпараметры),
- $\sum_{k=1}^{n} \lambda_k = 1$.

Линейная интерполяция

$$P(\text{mat} \mid \text{cat on a}) = \frac{N(\text{cat on a mat})}{N(\text{cat on a})} = ?$$

zero

Пример (биграмма + униграмма):

$$P(y_i \mid y_{i-1}) = \lambda_2 \cdot \hat{P}(y_i \mid y_{i-1}) + \lambda_1 \cdot \hat{P}(y_i)$$

Если $\lambda_2 = 0.7$, $\lambda_1 = 0.3$:

- чаще доверяют биграммам
- всегда добавляют «фон» от униграмм, чтобы слова с нулевой биграммой тоже имели шанс

Сглаживание Лапласа

$$P(\text{mat} \mid \text{cat on a}) = \frac{\overbrace{N(\text{cat on a mat})}^{\text{zero}}}{N(\text{cat on a})} = ?$$

Идея

- искусственно увеличить частоты всех n-грамм на дельту, чтобы избежать нулевых вероятностей

$$\widehat{P}(\text{mat} \mid \text{cat on a}) = \frac{\delta + N(\text{cat on a mat})}{\delta \cdot |V| + N(\text{cat on a})}$$

Сглаживание Лапласа

$$P(\text{mat} \mid \text{cat on a}) = \frac{\overbrace{N(\text{cat on a mat})}^{\text{zero}}}{N(\text{cat on a})} = ?$$

Идея

- вычесть фиксированное значения (discounting) из частот встречаемости
- перераспределить вероятности для «хвоста» распределения
- учитывать не только частоту слова, но и **разнообразие контекстов**, в которых это слово встречается

Источник

Сглаживание Кнесера — Нея

Формула (биграмма для простоты)

$$P_{\text{KN}}(y_i \mid y_{i-1}) = \frac{\max(N(y_{i-1}, y_i) - D,\, 0)}{N(y_{i-1})} \;+\; \lambda(y_{i-1}) \cdot P_{\text{cont}}(y_i)$$

где:

- $N(y_{i-1}, y_i)$ — частота биграммы,
- $N(y_{i-1})$ — частота слова-контекста,
- D — дисконт (обычно 0.75),
- $\lambda(y_{i-1})$ — коэффициент нормализации (чтобы сумма вероятностей = 1),
- $P_{\text{cont}}(y_i)$ — «continuation probability»:

$$P_{\text{cont}}(y_i) = \frac{\#\{y_{j-1} : N(y_{j-1}, y_i) > 0\}}{\sum_w \#\{y_{j-1} : N(y_{j-1}, w) > 0\}}$$

Это вероятность встретить y_i **как продолжение в разных контекстах**.

Источник

В чём заключается основная проблема N-граммных языковых моделей?

Преимущества и недостатки N-gram

Преимущества

- **Простота реализации**
  Легко понять и закодировать
- **Высокая скорость**
  Быстро обучаются и делают предсказания
- **Эффективность для коротких последовательностей**
  Хорошо работают в задачах с ограниченным контекстом
- **Меньшие требования к данным**
  Могут быть обучены на относительно небольших корпусах

Недостатки

- **Проблема разрежённости данных**
  Редкие последовательности имеют нулевую вероятность
- **Отсутствие учёта длинных зависимостей**
  Не могут захватить контекст, выходящий за рамки N-1 слов
- **Сложность обработки редких слов**
  Не справляются со словами, не встречавшимися в обучении
- **Линейная зависимость**
  Не учитывают сложную семантику языка

Ограничения N-gram привели к появлению более сложных нейронных языковых моделей

Языковые модели neural

4

Нейронные языковые модели

Нейронные языковые модели используют сложные архитектуры глубокого обучения для моделирования языка, преодолевая ограничения N-gram моделей

RNN

- Первые нейронные сети для последовательностей
- Обрабатывают данные шаг за шагом, сохраняя скрытое состояние предыдущих шагов

LSTM

- Усовершенствованные RNN
- Способные лучше запоминать информацию на длинных последовательностях благодаря специальным «воротам» памяти

Transformer

- Революционная архитектура
- Использует механизм внимания для обработки всех токенов последовательности одновременно, что позволяет захватывать очень длинные зависимости

Идея

$$P(y_1, y_2, \ldots, y_n) = P(y_1) \cdot P(y_2|y_1) \cdot P(y_3|y_1, y_2) \cdot \cdots \cdot P(y_n|y_1, \ldots, y_{n-1}) = \prod_{t=1}^{n} P(y_t|y_{<t})$$

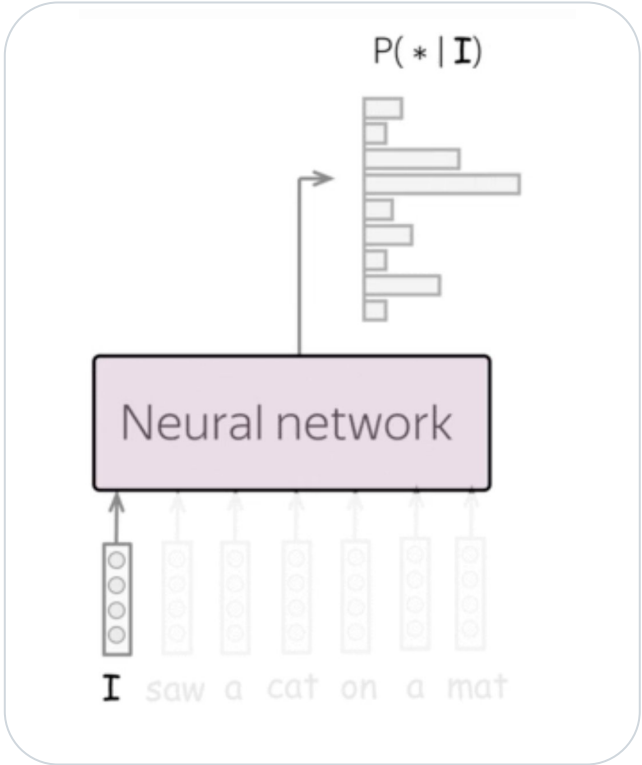
Задача — научиться считать $P(y_t|y_1, \ldots, y_{t-1})$

Классическое решение: вручную считать статистики встречаемости по корпусу

Нейросетевое решение: учить нейросеть предсказывать вероятности

Схема работы

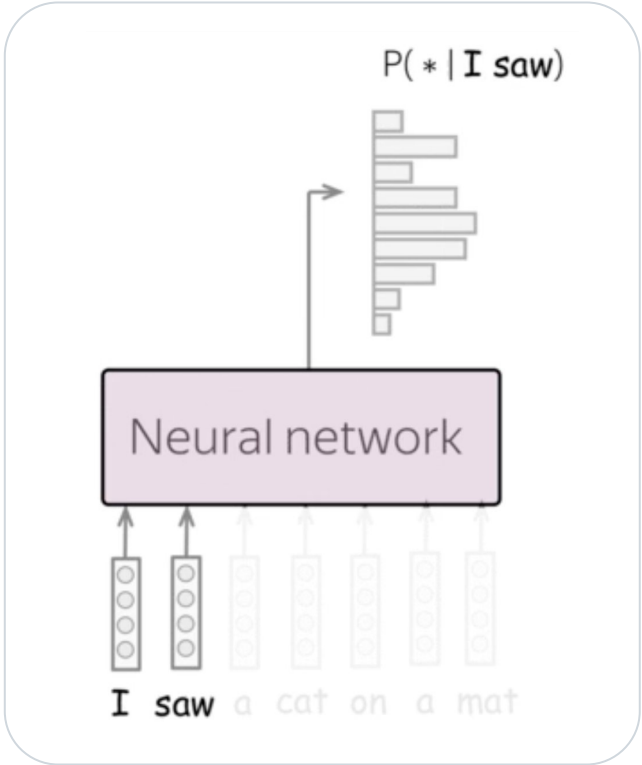
- Вход — эмбеддинги предыдущих слов (контекста), которые подаются в нейронную сеть
- Сеть обрабатывает входные данные и генерирует векторное представление контекста
- На основе полученного представления контекста модель предсказывает распределение вероятностей для следующего токена



Источник

Схема работы

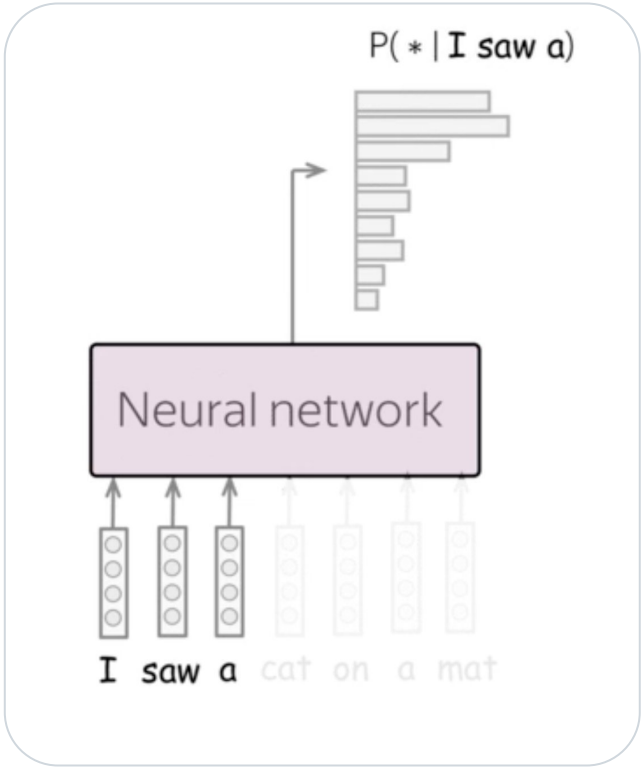
- Вход — эмбеддинги предыдущих слов (контекста), которые подаются в нейронную сеть
- Сеть обрабатывает входные данные и генерирует векторное представление контекста
- На основе полученного представления контекста модель предсказывает распределение вероятностей для следующего токена



Источник

Схема работы

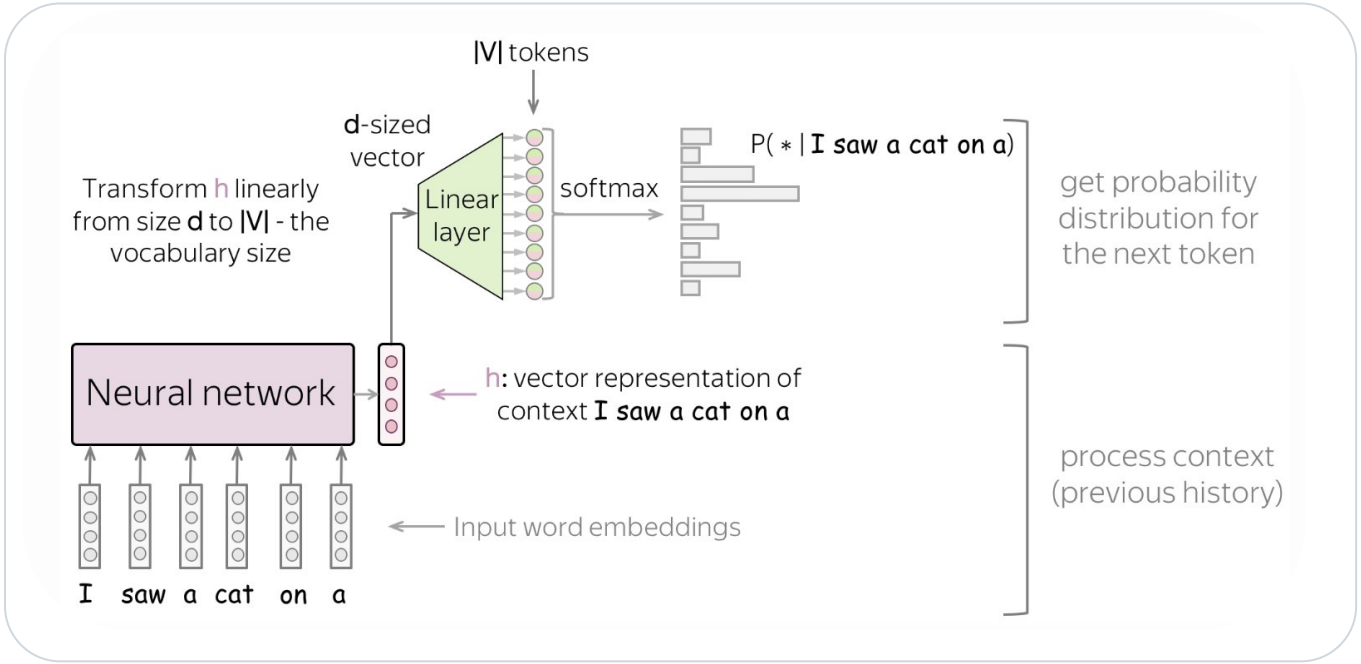
- Вход — эмбеддинги предыдущих слов (контекста), которые подаются в нейронную сеть
- Сеть обрабатывает входные данные и генерирует векторное представление контекста
- На основе полученного представления контекста модель предсказывает распределение вероятностей для следующего токена



Источник

На что это похоже?

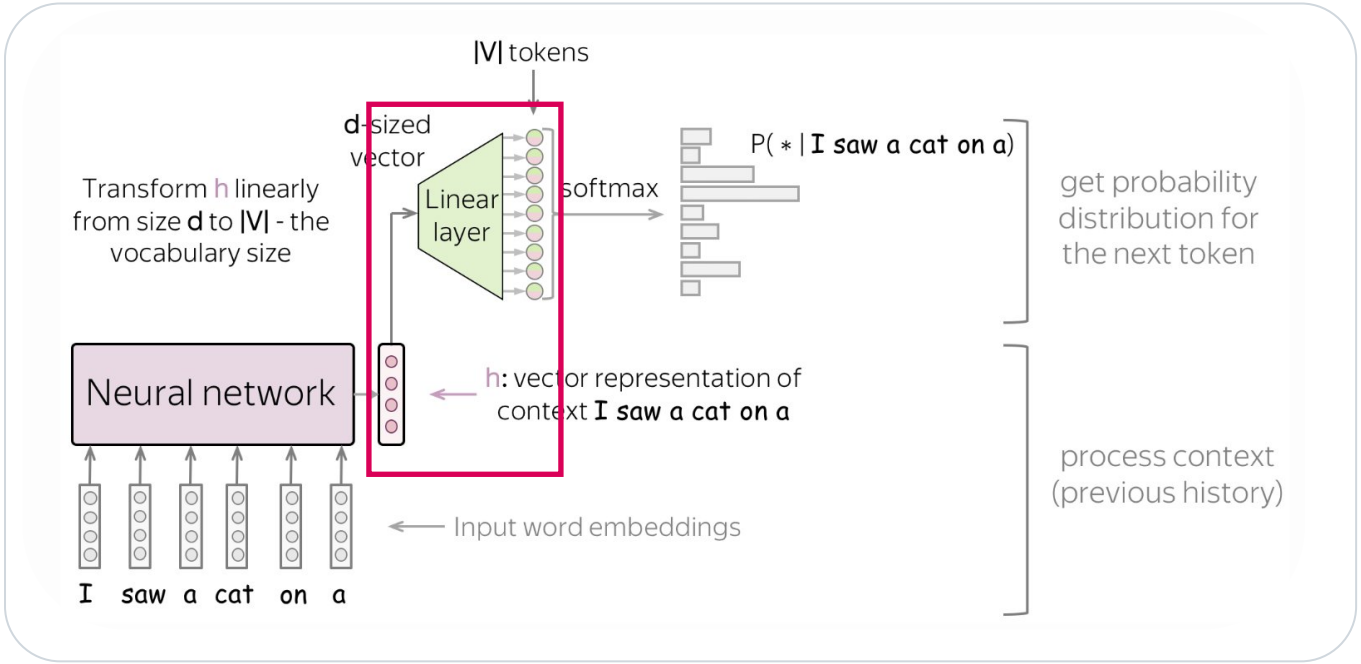
Схема работы



Многоклассовая классификация, |V| классов

Источник

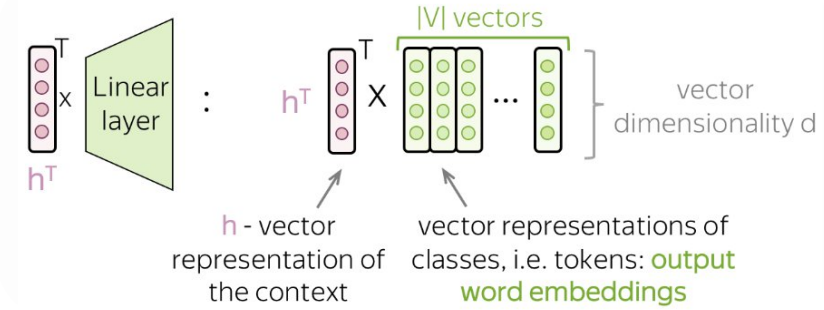
Схема работы



Многоклассовая классификация, |V| классов

Источник

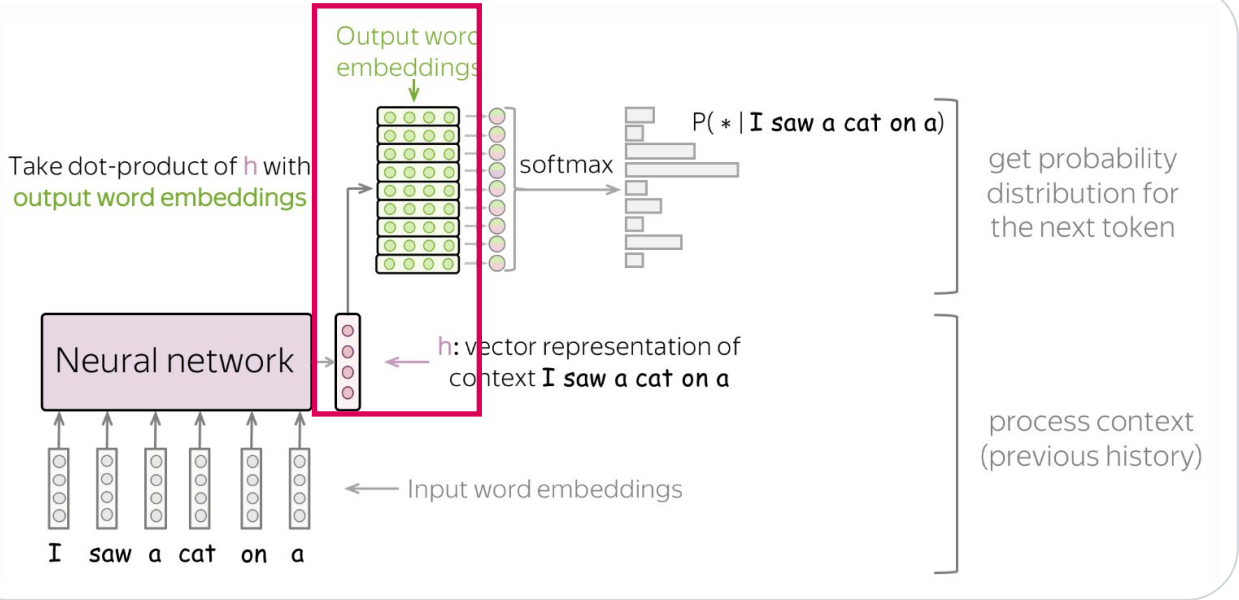
Схема работы



Каждый столбец матрицы весов можно рассматривать как выходной эмбеддинг токена словаря

Источник

Схема работы

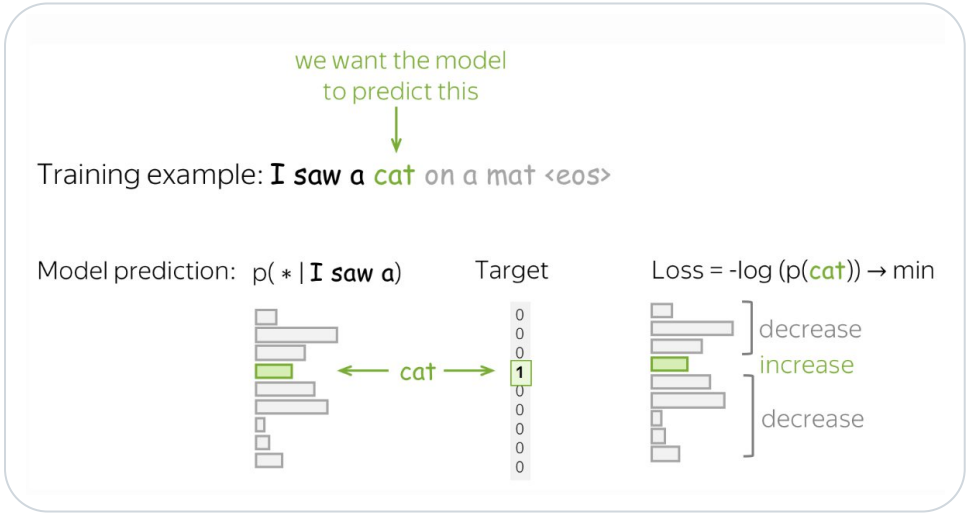


Задача — научиться считать $P(y_t|y_1,\ldots,y_{t-1})$

$$p(y_t|y_{<t}) = \frac{exp(h_t^T e_{y_t})}{\sum_{w \in V} exp(h_t^T e_w)}$$

Источник

Обучение — кросс-энтропия



Кросс-энтропийный лосс:

- p — предсказанная вероятность
- p* — истинная вероятность

$$Loss(p^*, p) = -p^* \log(p) = -\sum_{i=1}^{|V|} p_i^* \log(p_i).$$

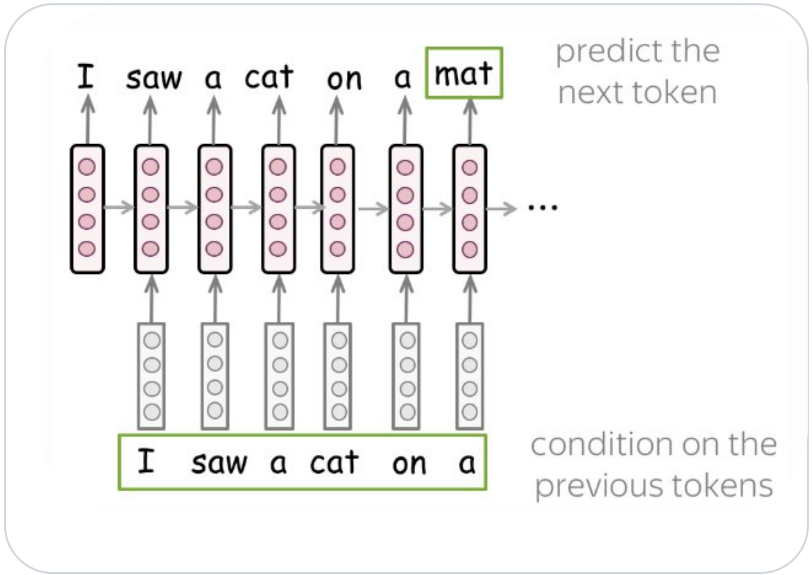
$$Loss(p^*, p) = -\log(p_{y_t}) = -\log(p(y_t|y_{<t})).$$

Лосс на каждом шаге — отрицательный логарифм вероятности правильного слова

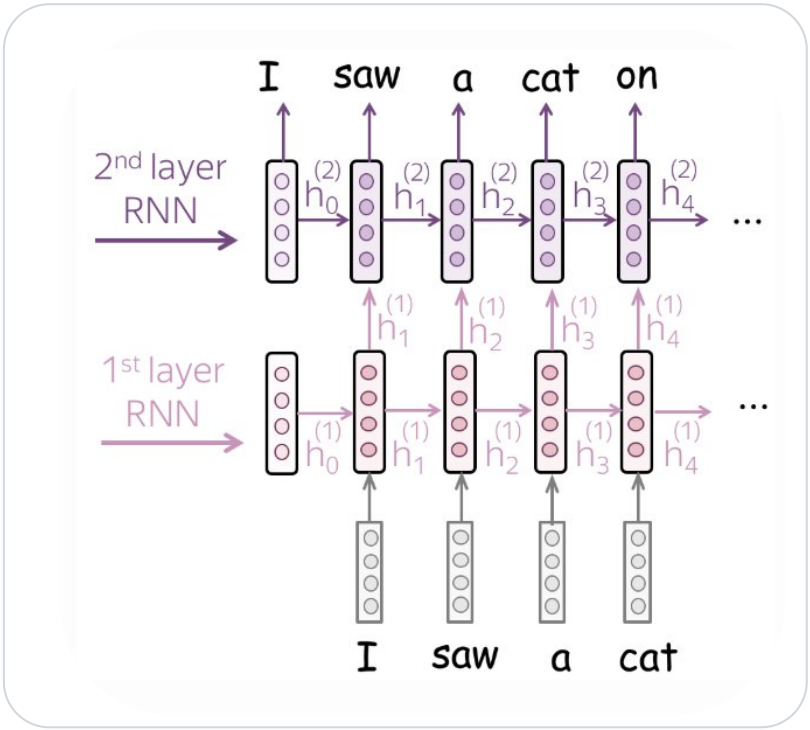
Источник

Языковая модель RNN

Однослойная RNN

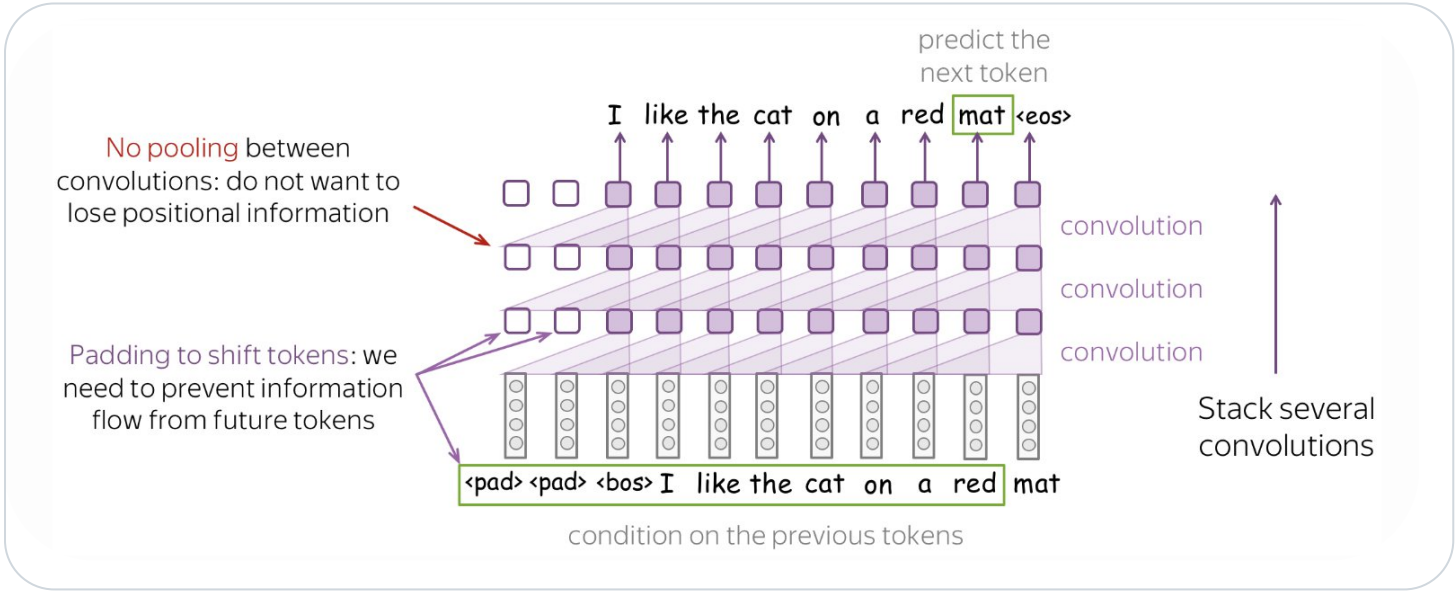


Многослойная RNN



Источник

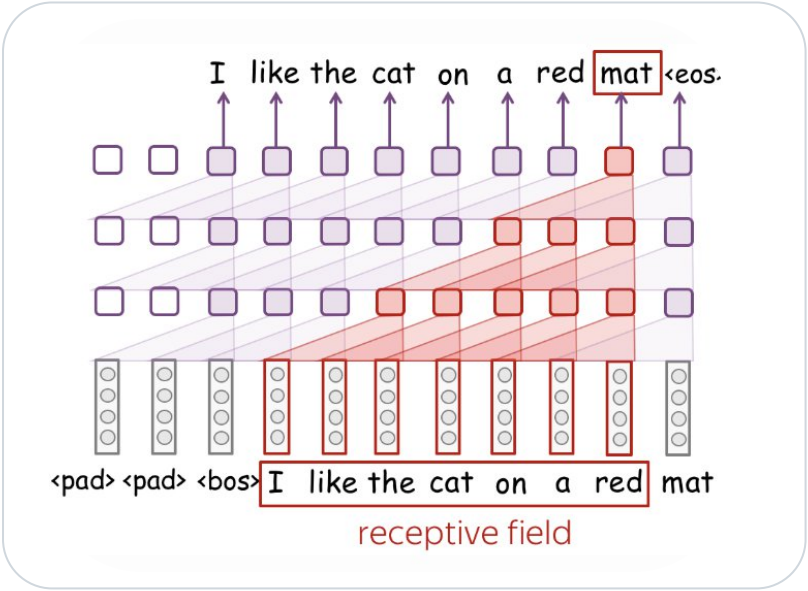
Языковая модель CNN



Источник

- Предотвращайте утечку информации от будущих токенов -> **добавляйте паддинг слева**
- Не удаляйте позиционную информацию -> **не используйте пуллинг**
- Если вы строите много слоев, не забывайте про **residual connections**

Языковая модель CNN



Контекст CNN LM

Рецептивное поле (контекст) — при большом количестве слоёв оно может быть большим:

- при использовании свёрточных моделей без глобального пулинга модель всегда будет иметь фиксированный размер контекста
- однако если для N-грамм типичный размер контекста составляет 1–4 токена, то в свёрточных моделях контекст может быть значительно длиннее
- например, с тремя свёрточными слоями с маленьким ядром (kernel size 3) сеть уже охватывает контекст из 7 токенов
- при увеличении количества слоёв длина контекста может стать очень большой

Источник

Языковая модель CNN

Идея

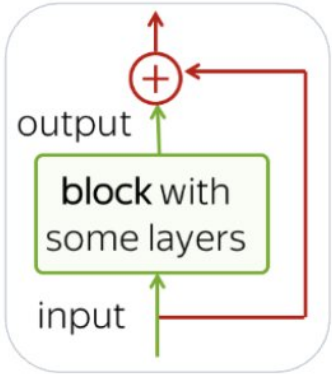
- для обработки длинных контекстов требуется много слоёв
- при большом количестве слоёв может возникнуть проблема распространения градиентов от верхних слоёв к нижним
- чтобы этого избежать, используют residual connections или их более сложный вариант — highway connections

Источник

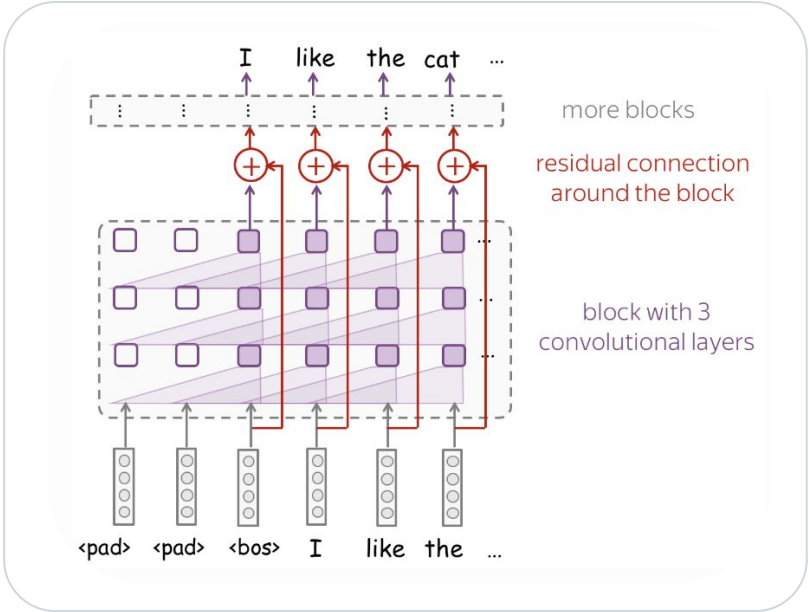
Языковая модель CNN

Residual connections

- Вход блока добавляется к его выходу
- Благодаря этому градиенты проходят не только косвенно через блок, но и напрямую через сумму входа и выхода



Residual connection



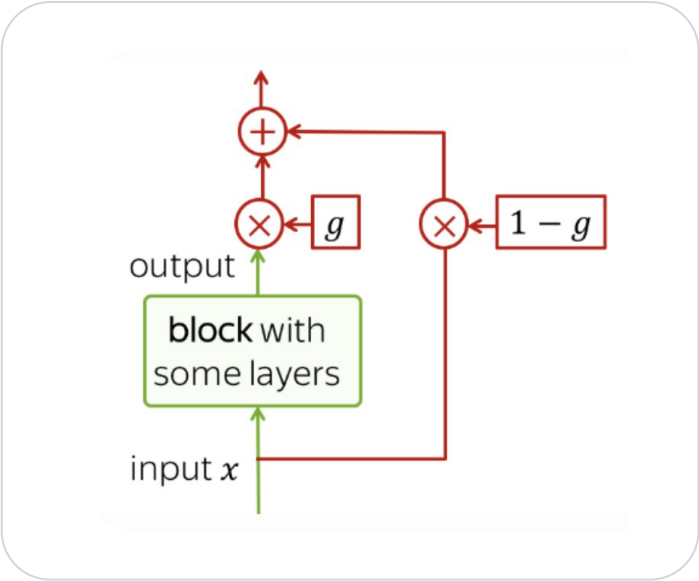
Пример CNN LM с residual connections

Источник

Языковая модель CNN

Highway connections

- Используют гейтовую сумму входа и выхода вместо простой суммы
- Похожи на LSTM-гейты, где сеть учится решать, какую информацию нужно передавать сверху вниз или, в случае LSTM, слева направо



Источник

Преимущества и недостатки нейронных моделей

Преимущества

- **Длинные зависимости**
  Отлично справляются с контекстом на больших расстояниях
- **Контекстное понимание**
  Учитывают семантику и синтаксис
- **Работа с редкими словами**
  Благодаря эмбеддингам
- **Масштабируемость**
  Могут обучаться на огромных данных

Недостатки

- **Вычислительная сложность**
  Требуют больших ресурсов для обучения
- **Сложность обучения**
  Требуют тонкой настройки и большого опыта
- **Потребность в данных**
  Для оптимальной работы необходимы огромные объёмы размеченных данных
- **Интерпретируемость**
  Труднее понять, как модель пришла к конкретному предсказанию

Несмотря на недостатки, нейронные сети стали стандартом для современных языковых моделей

Современные тенденции

Инновации в области языковых моделей формируют новые подходы и возможности

1

Предобученные (pre-trained) модели

- Общее языковое представление
- Обучение на огромных неразмеченных корпусах текстов, чтобы получить общее языковое понимание (BERT, GPT)

2

Трансферное обучение (transfer learning)

- Перенос знаний между задачами
- Использование предобученных моделей в качестве отправной точки для решения различных специфических задач

3

Дообучение (fine-tuning)

- Точная настройка под задачу
- Дообучение предобученных моделей на меньших датасетах, специфических для задачи

4

Мультимодальные модели (multimodal)

- Интеграция текста и изображений
- Способность обрабатывать и связывать информацию из нескольких модальностей, например текст + изображения

Домашнее задание

Домашнее задание

Пройти тест на платформе

Итоги

- LM — основа для генерации текста, перевода, анализа и многих других задач в NLP
- Предобученные модели и их дообучение (fine-tuning) — ключевой подход к созданию эффективных и адаптивных систем

Следующий вебинар

→ Способы генерации LM и оценка их качества. Практика

Введение в языковые модели (LM)

Руслан Аллаяров

