Способы генерации LM и оценка их качества. Практика

Руслан Аллаяров



Правила участия

1. Приготовьте блокнот и ручку,
чтобы записывать важные мысли и идеи
2. Продолжительность вебинара — 1 час 20 минут
3. Вы можете писать вопросы в чате
4. Запись вебинара будет доступна на платформе
5. Обсуждение можно продолжить в учебном чате

Проверка связи

Если у вас нет звука:

- убедитесь, что на вашем устройстве и на колонках включён звук
- обновите страницу вебинара (или закройте страницу и заново присоединитесь к вебинару)
- откройте вебинар в другом браузере
- перезагрузите компьютер (ноутбук) и заново попытайтесь зайти

Поставьте в чат:

\+ если меня видно и слышно

— если нет

Рекомендации

→ Если смотрите с компьютера

- Используйте браузеры Google Chrome или Microsoft Edge
- Если есть проблемы с изображением или звуком, обновите страницу — **F5**

→ Если смотрите с мобильного телефона или планшета

- Перейдите с мобильного интернет-соединения на **Wi-Fi**
- Если есть проблемы с изображением или звуком, перезапустите приложение на телефоне

Руслан Аллаяров

О спикере:

- окончил мехмат МГУ в 2021 г.
- обучался в аспирантуре Universität Wien
- преподавал дисциплины по C++ в ВШЭ и по информационному поиску в МГУ
- 5 лет занимался инфопоиском в VK
- ML-тимлид, руковожу рекомендациями на главной странице Okko



Цели занятия

- Разобрать основные методы и параметры в генерации языковых моделей
- Обсудить оценку качества языковых моделей

План занятия

1. Генерация языковых моделей. Методы и параметры
2. Оценка качества

Генерация языковых моделей. Методы и параметры

1

N-граммные LM, recap

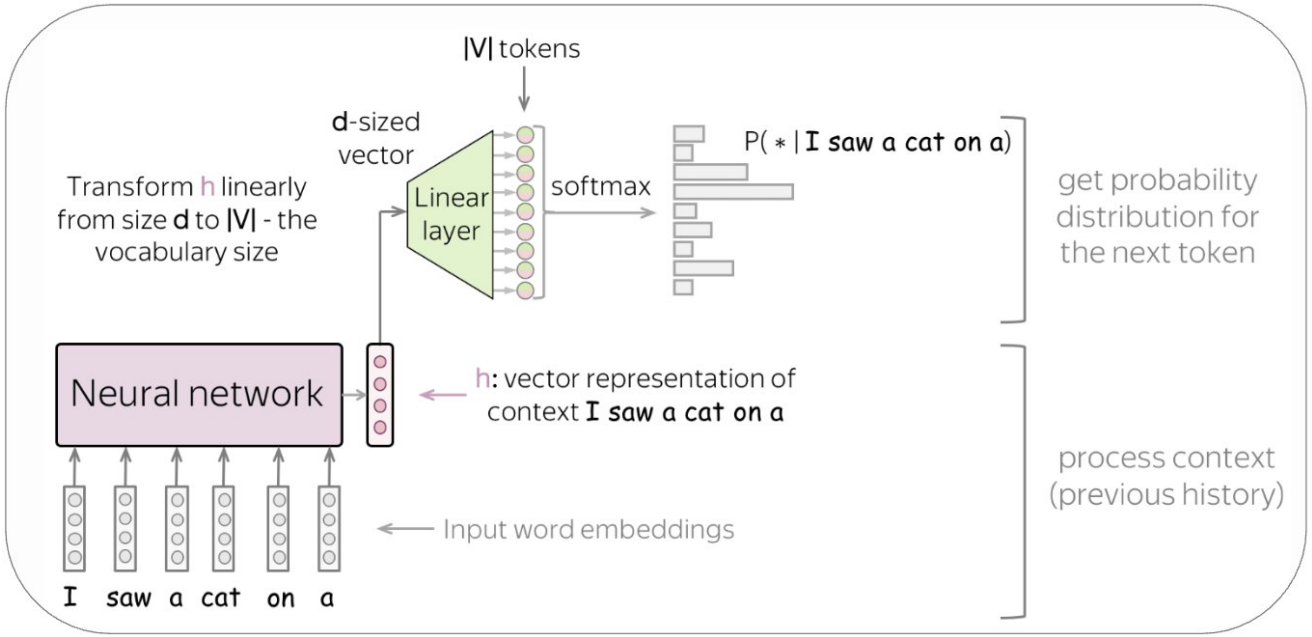
$$P(y_1, y_2, \ldots, y_n) = P(y_1) \cdot P(y_2|y_1) \cdot P(y_3|y_1, y_2) \cdot \cdots \cdot P(y_n|y_1, \ldots, y_{n-1}) = \prod_{t=1}^{n} P(y_t|y_{<t})$$

$$P(y_t|y_1, \ldots, y_{t-1}) = \frac{N(y_1, \ldots, y_{t-1}, y_t)}{N(y_1, \ldots, y_{t-1})}$$

$$P(y_t|y_1, \ldots, y_{t-1}) = P(y_t|y_{t-n+1}, \ldots, y_{t-1})$$

Вероятность слова зависит только от фиксированного числа предыдущих слов

Нейронные LM, recap



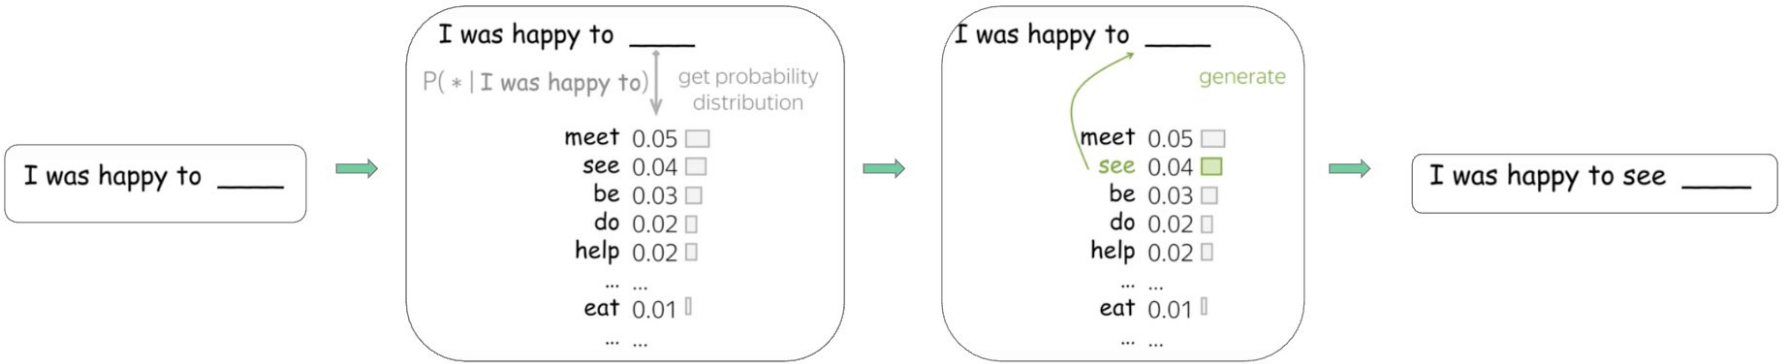
Многоклассовая классификация, |V| классов

Источник

Генерирование текста LM, recap

Основная идея:

- предсказываем распределение следующего токена по контексту предыдущих
- семплируем из этого распределения



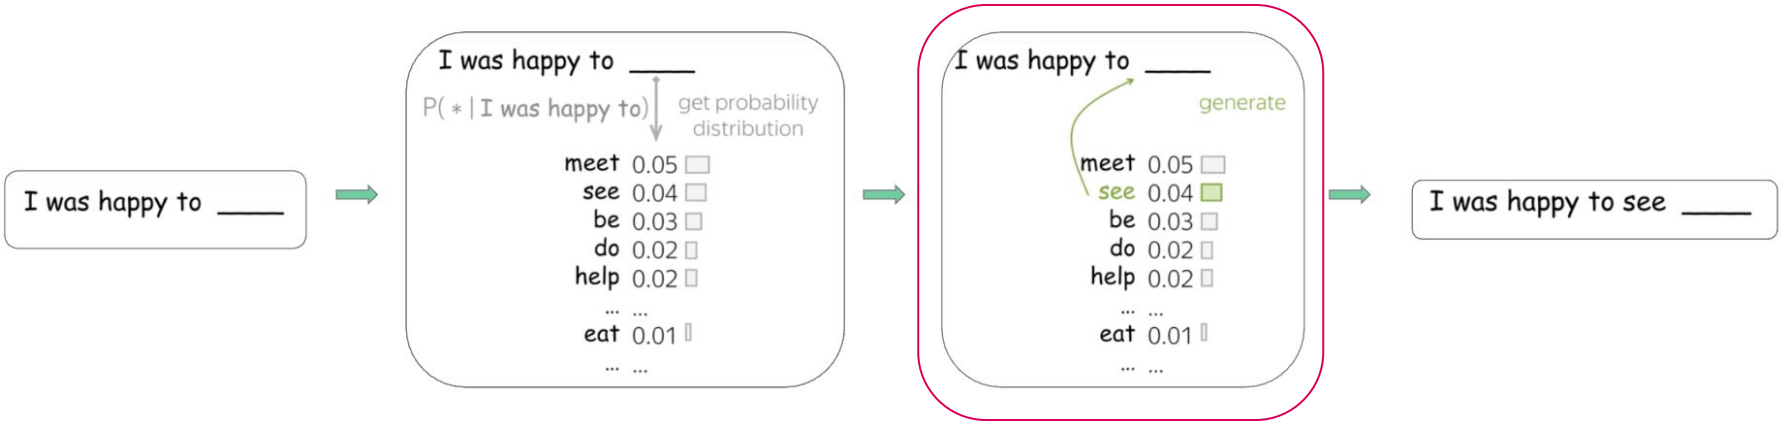
Источник

Генерирование текста LM верхнеуровнево

Основная идея:

- предсказываем распределение следующего токена по контексту предыдущих
- семплируем из этого распределения

Нужно научиться семплировать



Источник

Каким мы хотим увидеть сгенерированный текст?

Смысловая связность vs разнообразие

Нужно достигнуть 2 целей:

- **связность,** coherence — сохранение логики и последовательности
- **разнообразие**, diversity — чтобы текст не выглядел однообразным

Жадный декодинг, greedy decoding

Выбор самого вероятного токена на каждом шаге
без использования случайности.

Пример: «Моя кошка любит...»

- Высокие вероятности: молоко (0,60), спать (0,25), гулять (0,10)
- Низкие: космос (0,03), банан (0,02)

? **Какое будет продолжение?**

Жадный декодинг, greedy decoding

Выбор самого вероятного токена на каждом шаге
без использования случайности.

Пример: «Моя кошка любит...»

- Высокие вероятности: молоко (0,60), спать (0,25), гулять (0,10)
- Низкие: космос (0,03), банан (0,02)

Моя кошка любит молоко.

+ Плюсы:

- скорость
- связность

— Минусы:

- низкое разнообразие

Стандартное семплирование

Прямое семплирование из распределения вероятностей, предсказанного языковой моделью.

Пример: «Моя кошка любит...»

- Высокие вероятности: молоко (0,60), спать (0,25), гулять (0,10)
- Низкие: космос (0,03), банан (0,02)

Моя кошка любит молоко / спать / гулять / ...

Что может пойти не так в этом методе?

Стандартное семплирование

Прямое семплирование из распределения вероятностей, предсказанного языковой моделью.

Пример: «Моя кошка любит...»

- Высокие вероятности: молоко (0,60), спать (0,25), гулять (0,10)
- Низкие: космос (0,03), банан (0,02)

Моя кошка любит космос/банан.

Модель может выбрать редкие или маловероятные слова, из-за чего текст быстро съезжает в бессвязность.



Нужно менять семплирование!

Семплирование с температурой

До

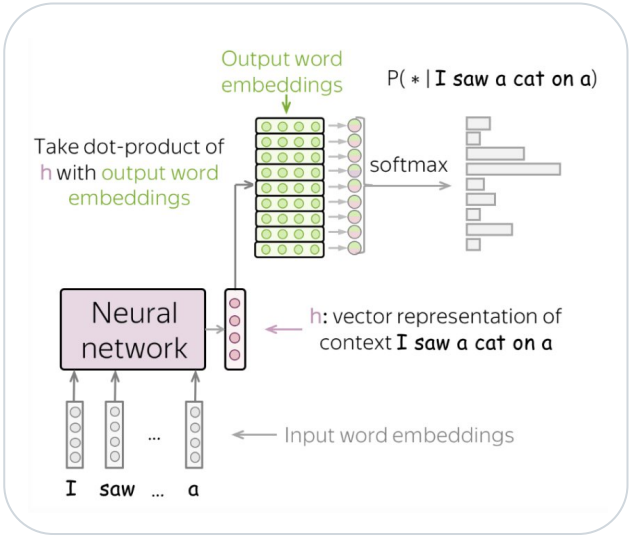


Схема neural LM

Источник

Семплирование с температурой

До

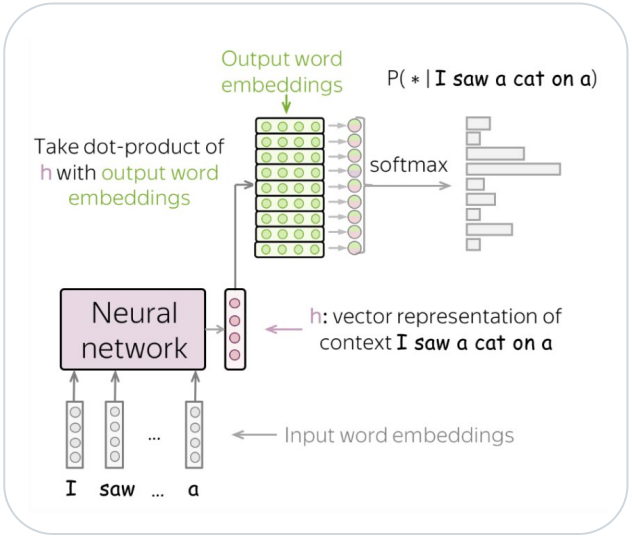
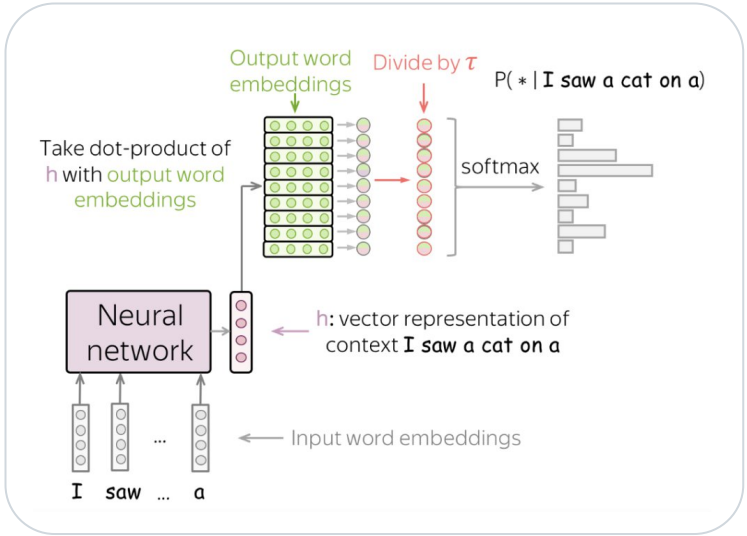


Схема neural LM

После



$$\frac{\exp(h^T w)}{\sum_{w_i \in V} \exp(h^T w_i)} \rightarrow \frac{\exp\left(\frac{h^T w}{\tau}\right)}{\sum_{w_i \in V} \exp\left(\frac{h^T w_i}{\tau}\right)}$$

τ - softmax temperature

Изменение логитов при предсказании LM

Источник

Семплирование с температурой

Температура softmax регулирует остроту распределения вероятностей.

Пример: «Моя кошка любит...»

- Высокие вероятности: молоко (0,60), спать (0,25), гулять (0,10)
- Низкие: космос (0,03), банан (0,02)

Применяем **пониженную T = 0,7**.

- Высокие вероятности: молоко (0,71), спать (0,20), гулять (0,07)
- Низкие: космос (0,015), банан (0,005)

В этом случае будет выбран более вероятный токен.

Как меняется связность и разнообразие?

Семплирование с температурой

Температура softmax регулирует остроту распределения вероятностей.

Пример: «Моя кошка любит...»

- Высокие вероятности: молоко (0,60), спать (0,25), гулять (0,10)
- Низкие: космос (0,03), банан (0,02)

Применяем **пониженную T = 0,7**.

- Высокие вероятности: молоко (0,71), спать (0,20), гулять (0,07)
- Низкие: космос (0,015), банан (0,005)

В этом случае будет выбран более вероятный токен.

Связность растёт, разнообразие падает

Семплирование с температурой

Температура softmax регулирует остроту распределения вероятностей.

Пример: «Моя кошка любит...»

- Высокие вероятности: молоко (0,60), спать (0,25), гулять (0,10)
- Низкие: космос (0,03), банан (0,02)

Применяем **повышенную T = 1,5.**

- Высокие вероятности: молоко (0,50), спать (0,22), гулять (0,15)
- Низкие: космос (0,07), банан (0,06)

В этом случае маловероятные токены могут быть выбраны.

Как меняется связность и разнообразие?

Семплирование с температурой

Температура softmax регулирует остроту распределения вероятностей.

Пример: «Моя кошка любит...»

- Высокие вероятности: молоко (0,60), спать (0,25), гулять (0,10)
- Низкие: космос (0,03), банан (0,02)

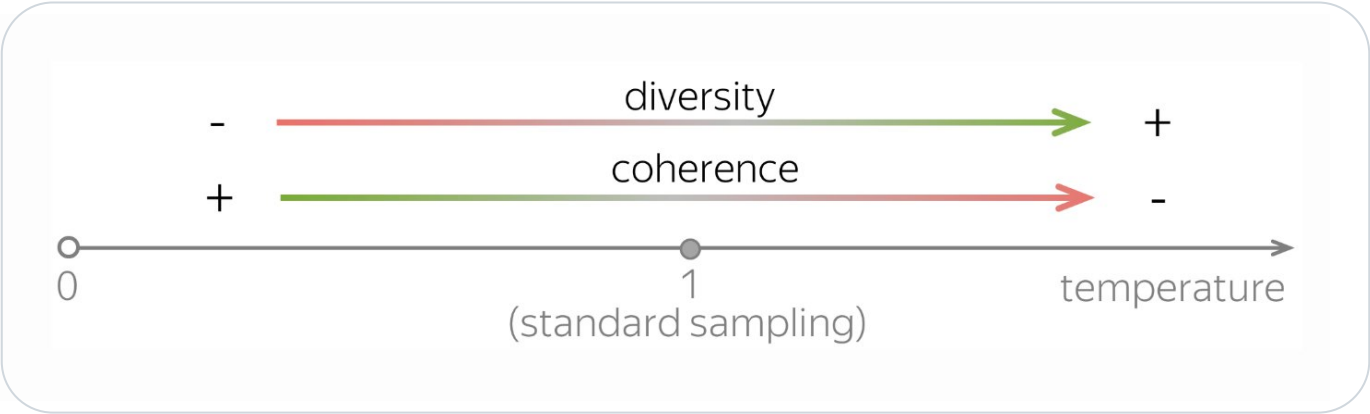
Применяем **повышенную T = 1,5.**

- Высокие вероятности: молоко (0,50), спать (0,22), гулять (0,15)
- Низкие: космос (0,07), банан (0,06)

В этом случае маловероятные токены могут быть выбраны.

Связность падает, разнообразие растёт

Семплирование с температурой



- Температура может помочь
- Не можем одновременно увеличивать и разнообразие, и связность

Источник

Семплирование с ограничением по K

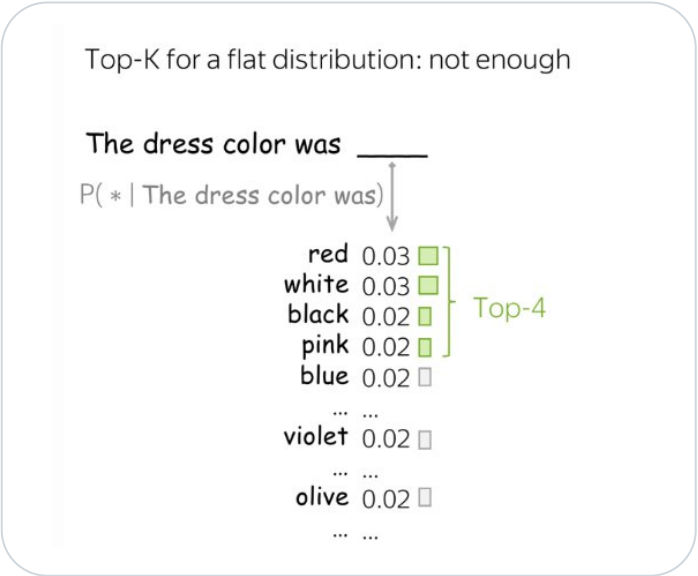


- Выбираются только K самых вероятных токенов по предсказанию модели
- Следующий токен выбирается случайным образом только среди них

Источник

Какие проблемы вы видите в этом методе?

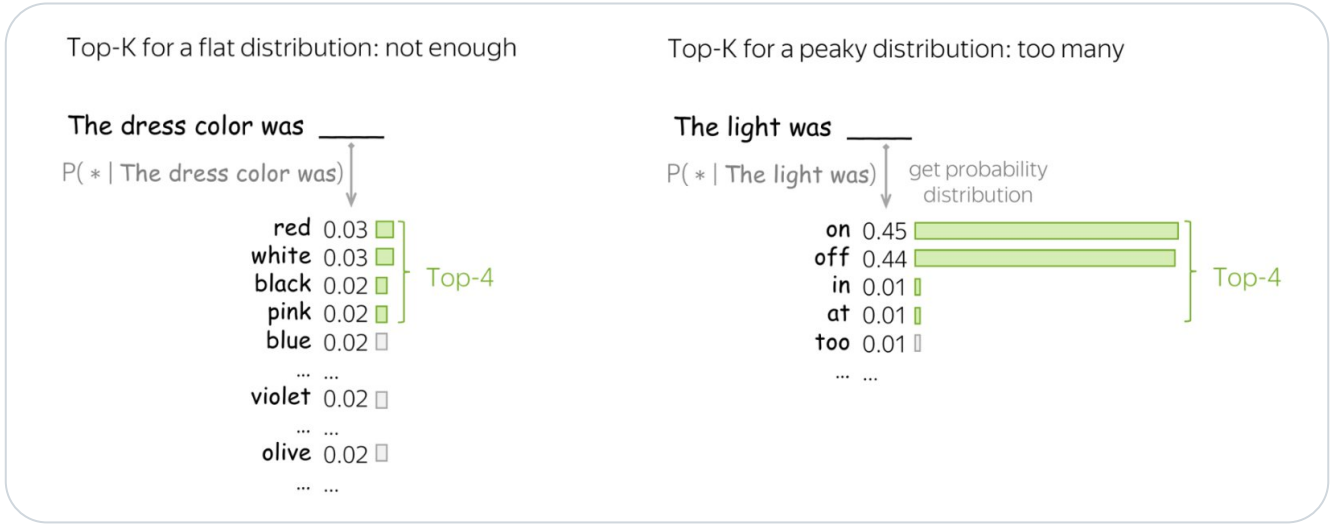
Семплирование с ограничением по K



Распределение равномерное, топ-K токенов могут покрывать очень малую часть суммарной вероятности

Источник

Семплирование с ограничением по K



Источник

- Распределение равномерное, топ-K токенов могут покрывать очень малую часть суммарной вероятности
- Распределение острое, топ-K могут включать маловероятные или странные токены, которые случайно попали в топ-K

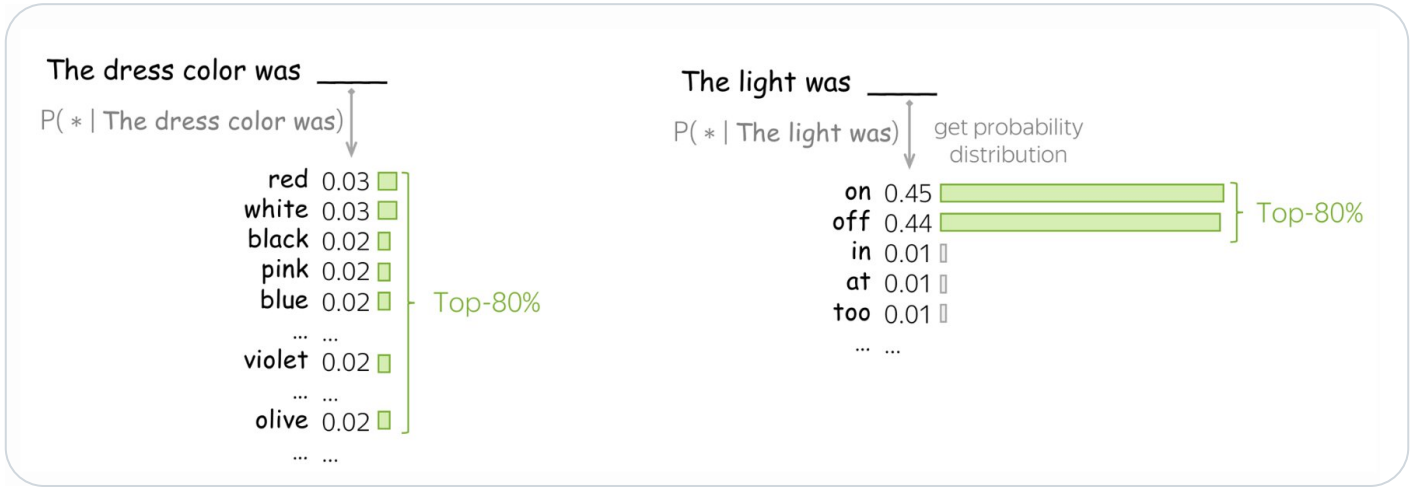
Вывод: фиксировать K не очень хорошая идея

Семплирование с ограничением по p, nucleus-семплирование

Идея: вместо фиксированного K выбирается минимальное множество токенов, сумма вероятностей которых ≥ p

Источник

Семплирование с ограничением по p, nucleus-семплирование



- В плоском распределении множество будет больше → учитываются многие токены
- В остром распределении множество будет меньше → фокус на наиболее вероятных токенах

Источник

Сравнение стратегий генерации

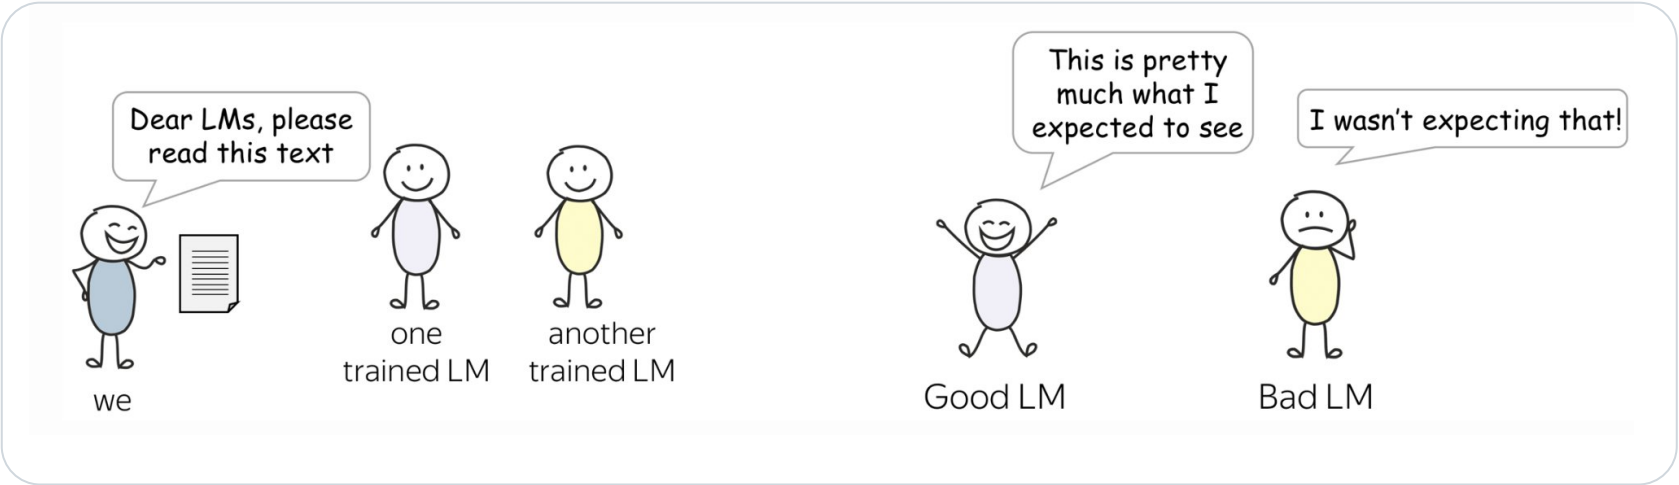
Метод	Связность текста	Разнообразие текста	Контроль над редкими токенами	Примечания
Greedy decoding	Высокая	Низкое	Нет	Простой и быстрый, но текст предсказуемый
Standard sampling	Средняя или низкая	Высокое	Нет	Может генерировать малосвязные или странные токены
Sampling with temperature (T)	Средняя или высокая, зависит от T	Среднее или высокое, зависит от T	Частично: низкая T → более вероятные токены, высокая T → все токены	Позволяет регулировать остроту распределения
Top-K sampling	Средняя	Среднее	Да, но фиксированное K → проблемы при плоских или острых распределениях	Уменьшает шанс выбора крайне редких токенов, но K фиксировано
Top-p sampling	Средняя или высокая	Высокое	Да, адаптивно	Адаптируется к форме распределения, балансирует разнообразие и качество текста

Оценка качества

2

Что такое хорошая LM?

Интуиция



Нужно определить, насколько модель удивляется новому тексту, т. е. насколько её предсказания соответствуют реальному тексту

Источник

Правдоподобие текста

Пусть есть тестовая последовательность токенов y_1, y_M.

Правдоподобие последовательности для модели p_θ вычисляется как:

$$p_\theta(y_1, \ldots, y_M) = \prod_{t=1}^{M} p_\theta(y_t \mid y_{<t})$$

Логарифм правдоподобия удобен для вычислений:

$$\log p_\theta(y_1, \ldots, y_M) = \sum_{t=1}^{M} \log p_\theta(y_t \mid y_{<t})$$

Для **нескольких документов**, например весь тестовый корпус:

$$\log p_\theta(D_{\text{test}}) = \sum_{i=1}^{N} \sum_{t=1}^{M_i} \log p_\theta(y_t^{(i)} \mid y_{<t}^{(i)})$$

N — количество документов
M_i — длина i-го документа

На что похожа модель?

Правдоподобие текста

Кросс-энтропия, cross-entropy
Определяет расстояние между истинным распределением токенов *q(y)* и предсказанным моделью *p(y):*

$$H(q,p) = -\sum_{y} q(y) \log p(y)$$

Для языковых моделей, где текст известен, $q(y_t) = 1$ для правильного токена y_t.

$$\text{Cross-Entropy} = -\frac{1}{M} \sum_{t=1}^{M} \log p(y_t \mid y_{<t})$$

Интерпретация: чем меньше кросс-энтропия, тем точнее модель предсказывает следующие токены.

Оценивание LM — на обратной функции к лоссу (кросс-энтропии)

Перплексия

Показывает, насколько хорошо модель предсказывает следующее слово в последовательности на основе предыдущих слов.

$$p_\theta(y_1, \ldots, y_M) = \prod_{t=1}^{M} p_\theta(y_t \mid y_{<t})$$ — правдоподобие текста

Какие проблемы есть у этой оценки?

Перплексия

$$p_\theta(y_1, \ldots, y_M) = \prod_{t=1}^{M} p_\theta(y_t \mid y_{<t})$$

- Это число экстремально маленькое для длинных текстов: у множаем много вероятностей < 1
- Число не нормировано

Перплексия

$$L(y_{1:M}) = L(y_1, y_2, \dots, y_M) = \sum_{t=1}^{M} \log_2 p(y_t | y_{<t})$$

Логарифм правдоподобия

$$Perplexity(y_{1:M}) = 2^{-\frac{1}{M} L(y_{1:M})}$$

Перплексия

Какие значения принимает perplexity?

Перплексия

$$L(y_{1:M}) = L(y_1, y_2, \dots, y_M) = \sum_{t=1}^{M} \log_2 p(y_t | y_{<t})$$

Логарифм правдоподобия

$$Perplexity(y_{1:M}) = 2^{-\frac{1}{M} L(y_{1:M})}$$

Перплексия

Значения perplexity:

- 1 → модель предсказывает каждый токен точно
- |V| → на каждом шаге модель считает вероятными все токены одинаково, т. е. не имеет никакой информации о тексте

Перплексия

$$L(y_{1:M}) = L(y_1, y_2, \dots, y_M) = \sum_{t=1}^{M} \log_2 p(y_t | y_{<t})$$

Логарифм правдоподобия

$$Perplexity(y_{1:M}) = 2^{-\frac{1}{M} L(y_{1:M})}$$

Перплексия

Физический смысл

Среднее количество вероятных вариантов, которые модель рассматривает на каждом шаге:

- 1 → модель предсказывает каждый токен идеально
- |V| → модель выбирает случайно из словаря

Итоги

- Изучили стратегии семплирования для создания текста: жадный декодинг, стандартное семплирование, семплирование с температурой, top-K и top-p, или nucleus-семплирование. Каждый метод обеспечивает разный баланс между связностью и разнообразием генерируемого текста

- Рассмотрели влияние параметра температуры в softmax на остроту распределения вероятностей токенов. При низкой температуре (T = 0,7) повышается связность текста за счёт снижения разнообразия, а при высокой (T = 1,5) увеличивается креативность, но может пострадать логичность

- Узнали, что такое перплексия. Метрика показывает среднееколичество вероятных вариантов, которые модельрассматривает на каждом шаге: значение 1 означает идеальное предсказание, а |V| (размер словаря) —случайный выбор

Следующий вебинар

Анализ и интерпретируемость LM. Сдвоенная практика

Способы генерации LM и оценка их качества. Практика

Руслан Аллаяров

