

Анализ тональности киноотзывов

Отчёт по обработке естественного языка · 9 октября 2026 года

Задача

Разработан Telegram-бот, который принимает русскоязычный отзыв о фильме и определяет его тональность: положительную, отрицательную или нейтральную. Нейтральный класс включает смешанные оценки без явного перевеса. Для классификации используется TF-IDF и логистическая регрессия.

Данные и их подготовка

Для обучения выбран корпус **100k Movie Reviews from Kazakhstan** (Rustem Yeshpanov, 2026), собранный с kino.kz. Он соответствует предметной области бота: пользователи оценивают фильмы и описывают впечатления от просмотра. Корпус содержит 100 502 записи на русском, казахском и смешанном языке. В каждой записи указаны идентификатор фильма, текст, язык и тональность. Данные поставляются в формате Parquet; даты публикаций и сведения об авторах отсутствуют. Лицензия источника - CC BY 4.0. [Описание и версия датасета](#).

В работе использованы 96 749 русскоязычных отзывов. После удаления повторов осталось 96 691. Фильмы в обучающей, валидационной и тестовой выборках не пересекаются.

Выборка	Отзывов	Отрицательные	Нейтральные	Положительные
Обучающая	76 971	21 482	3 290	52 199
Валидационная	10 396	2 825	436	7 135
Тестовая	9 324	2 619	411	6 294

Классы несбалансированы: в обучающей выборке 67,82% положительных отзывов и только 4,27% нейтральных. Поэтому наряду с accuracy используется macro-F1, в котором каждый класс имеет одинаковый вес.

Проверка обязательных полей, типов и допустимых меток не выявила технически некорректных записей. При очистке удалены 9 точных и 49 близких повторов - 0,0599% русскоязычной части. Для поиска дубликатов текст приводился к Unicode NFC и единому регистру, удалялись невидимые символы и лишние пробелы. Близкие копии искались по сходству символьных триграмм с порогом Jaccard 0,9; решения об удалении сохранены в журнале. Между подготовленными выборками точных текстовых совпадений нет. Внутри тестовой выборки остались 7 пар близких копий.

Отсутствие технических дефектов не означает безошибочную разметку. При проверке 100 обучающих отзывов с помощью ИИ 80 меток были сочтены обоснованными, 15 случаев - неоднозначными, для 5 предложена другая метка. Человек дополнительно рассмотрел 15 спорных случаев. Исходные метки сохранены. Этот аудит помогает выявить типичные проблемы, но не позволяет оценить долю смыслового шума во всём корпусе. [Результаты проверки данных](#).

Качество транскрипций

Обучающий корпус состоит из письменных отзывов. Для него длительность аудио и качество транскрипций неприменимы. Распознавание речи проверено отдельно на 12-секундном фрагменте записи преподавателя: OGG/Opus, 48 кГц, один канал. Использовалась модель Whisper small через faster-whisper в режиме CPU int8.

Расшифровка сверена с текстом, проверенным человеком. После нормализации регистра и пунктуации ошибок в 24 словах не обнаружено: WER = 0%. Это результат одного отладочного примера; для оценки качества на голосовых отзывах нужна отдельная аудиовыборка. Whisper используется только для распознавания речи и не участвует в классификации текста.

Метод классификации

Текст представляется вектором TF-IDF по словам и парам соседних слов. Перед векторизацией применяется приведение к нижнему регистру. Учитываются токены длиной от двух символов, встречающиеся минимум в двух документах и не более чем в 98% обучающих документов. Размер словаря ограничен 100 000 признаков; используются логарифмическое масштабирование частоты и L2-нормировка. Словарь и IDF рассчитываются только на обучающей выборке.

Логистическая регрессия выбрана как простой и воспроизводимый метод: она обучается на CPU, работает с разреженными векторами и позволяет исследовать вклад отдельных признаков. Для киноотзывов полезны оценочные слова и короткие сочетания. При этом такой подход ограниченно учитывает контекст, иронию и то, к какому объекту относится оценка.

Для компенсации дисбаланса заданы веса классов, рассчитанные по обучающей выборке. Параметр регуляризации C выбирался по macro-F1 на валидационной выборке:

C	Macro-F1
0,5	0,705051
1	0,716641
2	0,718015

Выбрано C=2. Оптимизатор - lbfgs, максимум 1 000 итераций, точность остановки 0,0001, seed=42. Трансформеры и ансамбли в классификаторе не используются. Соответствие выбранного метода перечню вебинара 4 отдельно не проверялось. [Конфигурация эксперимента](#).

Результаты

На 10 396 валидационных отзывах получено 9 246 правильных ответов и 1 150 ошибок. **Accuracy составила 88,9381%, macro-F1 - 0,718015.** Эта же выборка использовалась для выбора C, поэтому результат нельзя считать независимой итоговой оценкой. Тестовая выборка сохранена для дальнейшего сравнения моделей.

Класс	Precision	Recall	F1	Примеров
Отрицательный	0,870968	0,879292	0,875110	2 825
Нейтральный	0,274538	0,442661	0,338894	436
Положительный	0,960240	0,920673	0,940040	7 135

Лучше всего распознаются положительные отзывы. Нейтральный класс заметно сложнее: он малочисленен и объединяет как сдержанные, так и смешанные оценки. Высокая общая ассигасу частично объясняется преобладанием положительных примеров.

В матрице ошибок строки соответствуют исходным меткам, столбцы - предсказаниям модели.

Истина / прогноз	Отрицательный	Нейтральный	Положительный
Отрицательный	2 484	195	146
Нейтральный	117	193	126
Положительный	251	315	6 569

[Полные метрики](#).

Анализ ошибок

После классификации построена матрица ошибок и разобраны 40 неверных предсказаний. В разбор вошли четыре самых коротких текста и примеры всех шести направлений путаницы классов. Первичные объяснения подготовлены с помощью ИИ, затем проверены человеком: с 30 объяснениями он согласился, с 10 - частично. Проверяющий видел предложенные объяснения; независимая слепая разметка не проводилась.

Разбор выявил несколько характерных ситуаций:

- **Редкие написания.** В примере №1 положительное растянутое междометие отсутствовало в словаре. Вектор оказался нулевым, и модель выбрала *neutral* по свободным членам классификатора.
- **Короткий текст.** В примере №4 модель распознала только одно слово. Его вклада оказалось недостаточно для выбора *positive*; итоговым классом стал *neutral*.
- **Близкие оценки классов.** В примере №11 отрицательный отзыв отнесён к *neutral* с перевесом 0,0697 в линейных оценках. Однозначно объяснить ошибку конкретной языковой особенностью не удалось.
- **Объект оценки.** В примере №14 похвала относилась к книге, а не к фильму. Модель выбрала *positive* вместо *neutral*. Вероятная причина - опора на положительную лексику без учёта объекта высказывания.
- **Ирония.** В примере №36 финальная фраза меняла смысл предшествующей похвалы. Модель сохранила *positive*, хотя исходная метка была *negative*.

Эти примеры показывают, где локальных лексических признаков недостаточно. Они отобраны для анализа и не отражают частоты причин ошибок во всём корпусе. [Разбор 40 примеров с идентификаторами записей.](#)

Telegram-бот

Бот принимает текстовые киноотзывы длиной до 2 000 символов, возвращает метку и уверенность модели. Доступны команды `/start` и `/help`. Некорректный ввод и недоступность модели обрабатываются отдельными сообщениями. Значение уверенности показывает оценку классификатора, а не гарантированную вероятность правильного ответа.

Работа интерфейса проверена реальными запросами 8 октября 2026 года. В демонстрации использовалась отдельно переобученная модель: её *macro-F1* составила 0,718447 против 0,718015 у модели из раздела «Результаты». Поэтому демонстрация подтверждает работу бота, а качество классификации оценивается по сохранённому эксперименту. Для этой модели локально проверено совпадение результатов прямого вызова и обработчика бота. На коде проекта прошли 459 автоматических тестов. [Протокол проверки.](#)

Выводы и воспроизведение

TF-IDF и логистическая регрессия позволили реализовать классификацию киноотзывов без трансформеров и подключить её к Telegram. Основное ограничение - распознавание нейтральных оценок: *F1* этого класса составляет 0,339. Следующий этап исследования - независимая оценка на тестовой выборке и проверка переноса с письменных отзывов на разговорные сообщения.

Код, настройки, метрики и подробные протоколы доступны в [репозитории ru-review-sentiment-bot](#). Эксперимент зафиксирован версией `nlp-v1`; редакция настоящего отчёта - `nlp-v1.1`. Для воспроизведения нужны исходные данные и сохранённая модель; доступ к корпусу может требовать разрешения автора. Использованы Python 3.13.7 и `scikit-learn` 1.7.2. Установка и запуск описаны в README репозитория.