

Анализ тональности киноотзывов

Промежуточный отчёт по NLP · 09.10.2026 · Черновик для проверки

1. Задача и данные

Цель - классифицировать русскоязычный киноотзыв, поступивший текстовым сообщением Telegram, в один из трёх классов: negative=0, neutral=1, positive=2. Оценивается отношение к фильму; смешанная оценка без явного перевеса относится к neutral. Telegram служит интерфейсом ввода, а обучение проводится на письменных отзывах с kino.kz. Перенос на произвольные темы сообщений не проверен.

Используется **100k Movie Reviews from Kazakhstan**, Rustem Yeshpanov (2026), конфигурация pc, ревизия 526df6aa3fd9c99cddb2e2ce79406ae67816c1f9. Заявленная лицензия - CC BY 4.0. Исходные файлы сохранены без изменений; русскоязычная выборка после дедупликации - производные данные. [Источник и атрибуция](#).

Корпус содержит **100 502 записи** в трёх Parquet-файлах: 96 749 русскоязычных, 2 639 казахоязычных и 1 114 со смешением языков. Поля: movie_id, review_text, review_sentiment, review_language. Даты публикаций и демография авторов отсутствуют. Разбиение выполнено по фильмам.

Выборка	До очистки, ru	После очистки	Negative	Neutral	Positive
train	77 022	76 971	21 482	3 290	52 199
validation	10 403	10 396	2 825	436	7 135
test	9 324	9 324	2 619	411	6 294

Итого после подготовки - **96 691 строка**. В train доля positive составляет 67,82%, neutral - 4,27%. Числа test приведены из ранее сохранённого аудита данных: предсказания модели на финальном test для этой сдачи не вычислялись.

2. Качество и ограничения разметки

Технический дефект определён как пропущенное, нестроковое или пустое обязательное поле либо недопустимая метка/язык. Таких строк **0 / 100 502**. Удалены 9 точных повторов и 49 подтверждённых близких копий: **58 / 96 749 = 0,0599%** русскоязычных строк. Это доля исключённых повторов, а не всего смыслового шума. Доля гарантированно чистых текстов неизвестна; neutral не считается шумом.

Пересечения фильмов и нормализованных точных текстов между подготовленными выборками отсутствуют. Ограниченный поиск близких копий не доказывает отсутствие всех утечек; в test сохранены 7 пар близких копий (14 строк), их влияние предстоит оценить позднее.

Разметка источника выполнена одним автором; межэкспертное согласие не измерено. Агент просмотрел 100 train-отзывов: 80 счёл обоснованными, 15 неоднозначными, в 5 предложил другую метку. Пользователь проверил 15 выбранных случаев. Это не независимая человеческая проверка всей сотни и не оценка частоты ошибок во всём корпусе. **Исходные метки не изменялись.** [Подробный аудит](#).

3. Предобработка и выбор метода

Реализована следующая последовательность:

- Проверка контрольных сумм, схемы и допустимых значений; отбор review_language=ru. Исключение 3 753 иноязычных строк ограничивает область эксперимента и не означает плохого качества этих текстов.
- Поиск повторов по ключу Unicode NFC → casefold → удаление невидимых символов → свёртка пробелов. Для близких копий применяется Jaccard по символьным триграммам с порогом 0,9 и сохранённые решения команды. При удалении приоритет сохранения: test, затем validation, затем train.
- Ключ поиска дубликатов **не подменяет исходный текст модели**. Для классификации используются lowercase, словные униграммы и биграммы, TF-IDF с min_df=2, max_df=0.98, максимумом 100 000 признаков, sublinear TF и L2-нормировкой. Токены длиной от двух символов; без лемматизации и усечения текста.

Словарь и IDF обучаются только на train. При равной частоте отбор признаков разрешается порядком Unicode; это устраняет неоднозначность состава словаря на границе лимита. [Реализация и протокол](#).

Классификатор - Logistic Regression поверх TF-IDF, без трансформеров. Лексические признаки подходят для выраженной оценки фильма; модель обучается на CPU, имеет компактный интерфейс предсказания и позволяет исследовать вклады признаков. Ограничения - дальний контекст, объект оценки, ирония, редкие написания и неоднородный neutral.

Весы классов рассчитаны только по train (balanced_train). Для $C \in \{0.5, 1, 2\}$ получены validation macro-F1 0,705051; 0,716641; 0,718015. Выбран **C=2**, правило - максимум macro-F1, при равенстве меньший C. Используются lbfgs, max_iter=1000, tol=0.0001, seed=42. [Конфигурация](#).

Материалы вебинара 4 в доступном репозитории не найдены, поэтому соответствие именно перечню методов вебинара пока не подтверждено. Ансамбль не реализован; дополнительные 5 баллов за него не заявляются. RuBERT в классификации этой сдачи не используется.

4. Качество транскрипций

Обучающие тексты письменные: длительность, аудиопараметры и точность транскрипций для них неприменимы. Отдельно проверен отладочный фрагмент речи преподавателя 00:10-00:22: 12 с, OGG/Opus, 48 кГц, моно; Whisper small через faster-whisper, CPU int8. Это ASR-модуль, а не классификатор тональности.

На подтверждённом пользователем 07.10.2026 эталоне **WER = 0 / 24 = 0%**. Для сравнения применены NFC, casefold, замена пунктуации пробелами и разбиение на слова. Один короткий фрагмент с видимой гипотезой ASR не даёт независимой оценки качества всех голосовых сообщений. Доля шумных/чистых аудиосегментов не размечена. Финальные 36 голосовых записей здесь не использованы. [Протокол WER и ограничения](#).

5. Результаты классификации

Оценка проведена на всех **10 396 validation-отзывах**, уже использованных для выбора C. Правильных ответов - **9 246**, ошибок - **1 150**. **Accuracy = 88,9381%; macro-F1 = 0,718015**. Это промежуточные метрики, не независимая оценка на test. После анализа ошибок параметры этой сдачи не подгонялись.

Класс	Precision	Recall	F1	Число примеров
negative	0,870968	0,879292	0,875110	2 825
neutral	0,274538	0,442661	0,338894	436
positive	0,960240	0,920673	0,940040	7 135

Macro-F1 даёт равный вес классам и показывает слабость neutral, скрытую общей accuracy. В матрице строки - исходная метка, столбцы - прогноз.

Истина / прогноз	negative	neutral	positive
negative	2 484	195	146
neutral	117	193	126
positive	251	315	6 569

По шкале задания accuracy $\geq 90\%$ соответствует 10 баллам, $\geq 85\%$ - 8, $\geq 80\%$ - 5, $\geq 75\%$ - 3. Полученная validation accuracy попадает в диапазон 8 баллов, **но не гарантирует оценку преподавателя**. [Метрики и контрольные суммы](#).

6. Обработка после классификации и ошибки

После предсказания построены матрица ошибок и журнал **40 реальных неверных ответов**: четыре самых коротких текста и детерминированная выборка по шести направлениям путаницы классов. Объяснения подготовлены агентом. Человек проверил 40 из 40 случаев 09.10.2026: 30 согласий, 10 частичных. Это проверка после черновика ИИ, не слепая разметка; [оговорки сохранены](#). Это рабочая трактовка пункта задания «обработка после классификации», отдельно преподавателем не подтверждённая.

- **№1, row=00007583, positive → neutral**: редкое растянутое междометие отсутствует в словаре; вектор нулевой, ответ определяется свободными членами модели.
- **№4, row=00000814, positive → neutral**: распознано одно слово с нормированным весом 1. Вектор не нулевой; его вклад сближает оценки positive и neutral, но победу neutral обеспечивают свободные члены.
- **№11, row=00005025, negative → neutral**: отрицательный смысл ясен; перевес neutral в линейных оценках составляет 0,0697. Однозначная языковая причина не установлена.
- **№14, row=00010144, neutral → positive**: похвала относится к книге, а не к фильму. Возможная причина - смешение объектов оценки по положительной лексике.
- **№36, row=00001067, negative → positive**: финальная ироническая развязка меняет смысл длинной похвалы; модель сохраняет positive. Это пример ограничения локальных лексических признаков, не измерение всей способности распознавать сарказм.

Все ID относятся к validation-00000-of-00001.parquet. Полный [разбор 40 ошибок](#) содержит ID, метки и пояснения без публикации исходных отзывов. Частоты причин в этой специально подобранной выборке нельзя переносить на весь корпус.

7. Telegram: готовность и проверка

Текстовый бот реализован в [PR №29](#), исправленная версия 1dce425. Используется общий predict, классы negative/neutral/positive, команды /start и /help, лимит 2 000 символов. Ошибка модели или ввода должна давать сообщение, а не метку. Уверенность модели не означает гарантию правильности ответа.

По протоколу автора PR от 08.10.2026 выполнены реальные запросы Telegram с локально переобученной моделью. Её macro-F1 0,7184474571 отличается от принятого результата 0,7180146428; совпадение TF-IDF не доказывает идентичность полного классификатора. Эти результаты не заменяют метрики раздела 5.

После исправлений ревью локально прошли **459 тестов**; для трёх примеров прямой вызов и бот с принятым состоянием модели дали одинаковые результаты. Семь маршрутов диспетчера проверены без обращения к Telegram. **Реальная проверка Telegram с принятым комплектом пока не подтверждена; №26 не принята.** [Проверка исправлений](#). Голосовой режим в этой сдаче не заявляется.

8. Воспроизведение и версия

[Репозиторий проекта](#). Числа и анализ в отчёте закреплены на принятом commit **0e0a5fb9876b23f4e2758f86bf7a8b1735909f11**, а не на изменяемом master. Установка описана в [README этой версии](#). Python 3.13.7; scikit-learn 1.7.2; версии зависимостей зафиксированы.

Для N02 нужны локальные исходные train/validation, принятый комплект models/nlp_baseline/tfidf_logreg_baseline.joblib и окружение проекта. Данные и модель не вкладываются в отчёт. Доступ к исходному корпусу может требовать разрешения автора; публичность отчёта не означает открытый доступ к исходным файлам.

```
python tools/restore_nlp_splits.py
python tools/report_nlp_baseline.py
```

Первая команда восстанавливает train/validation по принятым ID, вторая проверяет комплект, считает метрики и воспроизводит выборку ошибок. Ни одна из этих команд не оценивает финальный test. Для восстановления модели после отдельного обучения и проверки её идентичности используется [протокол N02](#). Для WER необходим ранее проверенный локальный эталон; отсутствие файла не заменяется флагом подтверждения.

Текстовый запуск после получения версии бота из PR №29 и установки принятой модели: задать TELEGRAM_BOT_TOKEN в окружении и выполнить `python -m src.bot`. Токен в Git и отчёт не помещается; обучение не выполняется при запуске бота. На принятом commit 0e0a5fb этой точки входа ещё нет.

9. Что осталось до сдачи

- Завершить ревью №26 и реальную проверку Telegram с принятым комплектом; обновить раздел 7 и закрепить итоговый commit.
- Сверить метод с материалами вебинара 4; при уточнении преподавателем скорректировать трактовку «обработки после классификации».
- Проверить окончательный PDF и доступ к файлу и репозиторию без авторизации; зафиксировать готовую версию тегом nlp-v1.
- Прикрепить ссылку на окончательный файл в ЛМС и отдельно подтвердить отправку.

Это черновик, а не завершённая сдача. Тег nlp-v1 не создан; отправка в ЛМС не выполнена. Статус открытых действий и проверка доступности фиксируются отдельно в reports/nlp/submission_status.md, чтобы не выдавать подготовленный файл за уже сданную работу.